

دانشگاه صنعتی امیرکبیر  
(پلی تکنیک تهران)

---

## جبر خطی عددی

(کارشناسی)

فصل هفتم: تجزیه مقادیر تکین

مدرس: مهدی دهقان

---



دانشکده  
ریاضی و علوم کامپیوتر

---

۱۴۰۲-۱۴۰۳ ترم اول

## فهرست مطالب

۱	تجزیه مقادیر تکین (منفرد) ماتریس ها
۱.۱	منحصر به فرد بودن تجزیه مقدار تکین
۲	محاسبه تجزیه مقادیر منفرد
۳	حل دستگاه های خطی مربعی و غیرمربعی با تجزیه مقادیر تکین
۳.۱	خلاصه ای از حل دستگاه $AX = b$ با استفاده از روش تجزیه $SVD$ در حالتی که رتبه ماتریس ضرایب کامل است.
۴	رابطه بین مقادیر تکین یک ماتریس و دترمینان و عدد حالت و بعضی نرمهای ماتریسی آن ماتریس
۵	اثر یک ماتریس بر یک ناحیه یا یک شکل
۵.۱	اثر یک ماتریس متعامد بر یک شکل
۵.۲	اثر یک ماتریس قطری بر شکل دایره
۵.۳	تعییر هندسی تجزیه $SVD$
۶	کاربردهای تجزیه $SVD$
۶.۱	بهترین تقریب رتبه پایین یک ماتریس
۷	تصویر به صورت یک ماتریس
۷.۱	تبدیل تصاویر به ماتریس در نرم افزار متلب
۸	فسرده سازی تصویر
۸.۱	فسرده سازی تصویر رنگی
۶۱	واژه نامه انگلیسی به فارسی
۶۲	واژه نامه فارسی به انگلیسی

## ۱ تجزیه مقادیر تکین (منفرد) ماتریس ها

توجه: برای مطالعه هرچه بهتر این فصل، مرور الگوریتم گرام-اشمیت از فصل اول و محاسبه‌ی جفت ویژه‌های یک ماتریس از فصل پنجم ضروری است.

در فصل‌های قبل با ماتریس‌های قطری شدنی آشنا شدیم. ماتریس  $A$  را قطری شدنی گویند هرگاه ماتریس نامنفرد  $P$  موجود باشد که

$$A = PDP^{-1} \quad (1)$$

که در این صورت گوییم  $A$  با یک ماتریس قطری  $D$  متشابه است. وقتی ماتریس  $A$  را بتوان به صورت (۱) تجزیه نمود آنگاه می‌توان از فواید این تجزیه بهره برد. برای مثال می‌دانیم که  $\lambda(A) = \lambda(D)$  و عناصر قطری  $D$  همان مقادیر ویژه‌ی  $A$  خواهند بود.

یا مثلاً توان  $k$ -ام ماتریس  $A$  به راحتی از رابطه‌ی

$$A^k = PD^kP^{-1}$$

به دست می‌آید. توجه کنید که توان  $k$ -ام ماتریس قطری

$$D = \begin{bmatrix} d_1 & & & & \\ & d_2 & & & \\ & & \ddots & & \\ & & & \ddots & \\ & & & & d_n \end{bmatrix}$$

به راحتی از

$$D^k = \begin{bmatrix} d_1^k & & & & \\ & d_2^k & & & \\ & & \ddots & & \\ & & & \ddots & \\ & & & & d_n^k \end{bmatrix}$$

محاسبه می‌شود. اکنون ماتریس زیر را در نظر بگیرید

$$A = \begin{bmatrix} 1 & 2 \\ -2 & -3 \end{bmatrix}$$

با محاسبه‌ی جفت ویژه‌های  $A$  داریم.

$$\lambda_1 = \lambda_2 = -1, \quad X_1 = X_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$

چون  $A$  دارای دو بردار ویژه‌ی مستقل خطی نیست پس قطری شدنی نیست. بنابراین وجود تجزیه‌ای به صورت  $A = PDP^{-1}$  ممکن نیست ولذا محدودیت‌هایی در کار کردن با ماتریس  $A$  (در این مثال) می‌تواند به وجود آید (برای جزییات بیشتر به فصل اول مراجعه نمایید).

با توجه به اینکه در عمل ممکن است با ماتریس‌هایی سروکار داشته باشیم که قطری شدنی نباشد یعنی دارای تجزیه‌ای به شکل  $A = PDP^{-1}$  نباشد پس معقول است که به دنبال یک تجزیه‌ی جایگزین برای  $A$  باشیم که احتمالاً از خواص خوبی مانند آنچه در تجزیه‌ی قطری شدنی وجود دارد، برخوردار باشد. به علاوه چنین تجزیه‌ی جایگزینی می‌بایست برای هر ماتریس دلخواه موجود باشد و از محدودیت‌های تجزیه قطری شدنی برخوردار نباشد.

عموماً چنین تجزیه‌ای جایگزینی برای  $A$  وجود دارد که به صورت

$$A = U\Sigma V^T \quad (2)$$

بیان می‌شود که در آن  $U, V$  ماتریس‌هایی متعامدند یعنی

$$UU^T = U^T U = I, \quad VV^T = V^T V = I$$

و  $\Sigma$  ماتریسی قطری است. مثلا برای ماتریس همین مثال داریم

$$\begin{aligned} A &= \begin{bmatrix} 1 & 2 \\ -2 & -3 \end{bmatrix} = U\Sigma V^T \\ &= \begin{bmatrix} -0/5257 & 0/8507 \\ 0/8507 & 0/5257 \end{bmatrix} \begin{bmatrix} 4/2361 & 0 \\ 0 & 0/2361 \end{bmatrix} \begin{bmatrix} -0/5257 & -0/8507 \\ -0/8507 & 0/5257 \end{bmatrix}^T \end{aligned}$$

به علاوه چون  $V$  متعامد است پس  $V^T = V^{-1}$  و لذا رابطه (۲) را می‌توان به صورت زیر نوشت

$$A = U\Sigma V^{-1}, \quad (\Sigma \text{ ماتریس قطری است})$$

که شباهت فراوانی با رابطه‌ی قطری شدنی  $A = PDP^{-1}$  دارد.  
به تجزیه‌ی (۲) تجزیه‌ی مقادیر تکین (منفرد) (Singular Value Decomposition) یا به اختصار تجزیه SVD ماتریس  $A$  می‌گوییم.  
به عنوان مثالی دیگر ماتریس زیر را در نظر بگیرید

$$A = \begin{bmatrix} 3 & 2 & 2 \\ 1 & 2 & 2 \\ -1 & -1 & 0 \end{bmatrix}$$

با محاسبه‌ی جفت ویژه‌های  $A$  داریم.

$$\lambda_1 = 1, \quad \lambda_2 = 2, \quad \lambda_3 = 2, \quad X_1 = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}, \quad X_2 = X_3 = \begin{bmatrix} -2 \\ 0 \\ 1 \end{bmatrix}$$

چون  $A$  دارای سه بردار ویژه مستقل خطی نیست پس قطری شدنی نیست. بعلاوه می‌توان دید که

$$\begin{aligned} \begin{bmatrix} 3 & 2 & 2 \\ 1 & 2 & 2 \\ -1 & -1 & 0 \end{bmatrix} &= U\Sigma V^T = \begin{bmatrix} -0/7984 & 0/4400 & 0/4110 \\ -0/5545 & -0/8033 & -0/2172 \\ 0/2346 & -0/4013 & 0/8854 \end{bmatrix} \times \\ &\quad \begin{bmatrix} 5/1096 & 0 & 0 \\ 0 & 1/2152 & 0 \\ 0 & 0 & 0/6442 \end{bmatrix} \times \begin{bmatrix} -0/6232 & 0/7554 & 0/2022 \\ -0/5755 & -0/2678 & -0/7727 \\ -0/5296 & -0/5980 & 0/6016 \end{bmatrix}^T \end{aligned}$$

قضیه‌ی زیر که معمولا از آن با نام قضیه تجزیه مقادیر تکین (منفرد) یا قضیه SVD یاد می‌شود تضمین می‌کند هر ماتریس دلخواه دارای تجزیه SVD است.

## قضیه ۱

فرض کنید  $A$  یک ماتریس حقیقی  $n \times m$  باشد، آنگاه ماتریس‌های متعامد  $U$  و  $V$  وجود دارند به قسمی که

$$A = U\Sigma V^T,$$

و

$$\Sigma = \begin{bmatrix} \Sigma_1 & \circ \\ \circ & \circ \end{bmatrix}_{m \times n}$$

که در آن  $\Sigma$  یک ماتریس قطری نامنفرد است و عناصر قطری  $\Sigma$  همگی مثبت هستند.

اثبات: ماتریس  $A^T A$  را در نظر بگیرید. این ماتریس یک ماتریس  $n \times n$  نیمه معین مثبت متقارن است؛ بنابراین مقادیر ویژه آن نامنفی هستند. مقادیر ویژه  $A^T A$  را به صورت  $\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2$  نمایش می‌دهیم. فرض کنید

$$\sigma_1^2 \geq \sigma_2^2 \geq \dots \geq \sigma_r^2 > 0$$

$$\sigma_{r+1} = \sigma_{r+2} = \dots = \sigma_n = 0$$

قبله دیده‌ایم که یک ماتریس متقارن دارای یک مجموعه بردارهای ویژه متعامد (و در نتیجه یکامتعامد) است مجموعه بردارها ویژه یک متعامد  $A^T A$  متناظر با  $\lambda_1$  تا  $\lambda_n$  را با  $v_1, v_2, \dots, v_n$  نمایش می‌دهیم؛ یعنی  $v_1$  تا  $v_n$  یکامتعامد هستند و طبق تعریف مقدار ویژه و بردار ویژه در رابطه زیر صدق می‌کنند

$$A^T A v_i = \sigma_i^2 v_i, \quad i = 1, \dots, n$$

پس

$$v_i^T A^T A v_i = \sigma_i^2 v_i^T v_i = \sigma_i^2 \neq 0, \quad i = 1, \dots, r, \quad (3)$$

$$v_i^T A^T A v_j = \sigma_i^2 v_i^T v_j = 0, \quad i = 1, \dots, r; \quad j \neq i. \quad (4)$$

می‌نویسیم

$$V_1 = [v_1, \dots, v_r], \quad V_2 = [v_{r+1}, \dots, v_n] \quad (5)$$

که در آن  $v_1$  تا  $v_r$  بردارهای ویژه متناظر با مقادیر ویژه مخالف صفر  $\lambda_1$  تا  $\lambda_r$  و  $v_{r+1}, \dots, v_n$  بردارهای ویژه متناظر با مقادیر ویژه صفر  $\lambda_{r+1}$  تا  $\lambda_n$  هستند. پس

$$A^T A v_{r+1} = \lambda_{r+1} v_{r+1} = 0 \times v_{r+1} = 0,$$

$$A^T A v_{r+2} = \lambda_{r+2} v_{r+2} = 0 \times v_{r+2} = 0,$$

⋮

$$A^T A v_n = \lambda_n v_n = 0 \times v_n = 0.$$

حال می‌توان نوشت:

$$\begin{aligned} V_2^T A^T A V_2 &= V_2^T A^T A [v_{r+1}, v_{r+2}, \dots, v_n] \\ &= V_2^T [A^T A v_{r+1}, A^T A v_{r+2}, \dots, A^T A v_n] = V_2^T (0, 0, \dots, 0) = 0 \end{aligned}$$

این ایجاب می‌کند که  $0 = \|AV_2\|_2 = \|AV_2\|_F$  یا  $0 = \|AV_2\|_F = (AV_2)^T (AV_2) = V_2^T A^T A V_2 = 0$  پس یا

$$A [v_{r+1}, v_{r+2}, \dots, v_n] = [Av_{r+1}, Av_{r+2}, \dots, Av_n] = 0.$$

لذا

$$Av_k = 0, \quad k = r+1, r+2, \dots, n \quad (6)$$

اکنون یک مجموعه بردارهای مخالف صفر  $\{u_i\}$  را به صورت زیر تعریف می‌کنیم

$$u_i = \frac{1}{\sigma_i} Av_i, \quad i = 1, \dots, r \quad (7)$$

توجه کنید رابطه کسری فوق معنادار است زیرا مخرج کسر ناصرف است. بردارهای  $u_i, \dots, r$ ،  $u_i = 1, \dots, r$  یک مجموعه متعامد تشکیل می‌دهند، زیرا

$$\begin{aligned} u_i^T u_j &= \frac{1}{\sigma_i} (Av_i)^T \frac{1}{\sigma_j} (Av_j) \\ &= \frac{1}{\sigma_i \sigma_j} (v_i^T A^T A v_j) \\ &= \frac{1}{\sigma_i \sigma_j} (v_i^T \lambda_j v_j) \\ &= \frac{\sigma_j}{\sigma_i \sigma_j} (v_i^T v_j) \\ &= \begin{cases} \circ & i \neq j \\ 1 & i = j \end{cases} \end{aligned}$$

تعریف می‌کنیم  $(u_1, \dots, u_r) = U_1$  و  $(u_{r+1}, \dots, u_m) = U_2$  را به قسمی انتخاب می‌کنیم که  $U = (U_1, U_2)$  متعامد باشد (در مثال‌های صفحات بعد نشان می‌دهیم با استفاده از الگوریتم گرام-اشمیت چنین کاری شدنی است). سپس برای هر  $k > r$  و با استفاده از  $Av_i = \sigma_i u_i$  (که از (۶) به دست می‌آید) داریم:

$$u_k^T Av_i = u_k^T (\sigma_i u_i) = \sigma_i u_k^T u_i = \sigma_i \times \circ = \circ, \quad i = 1, \dots, r, \quad (8)$$

زیرا بردارهای  $u_i$  متعامد هستند. حال از (۶) داریم

$$u_k^T Av_i = u_k^T \times \circ = \circ, \quad i = r+1, \dots, n. \quad (9)$$

همچنین

$$u_k^T Av_k = \sigma_k u_k^T u_k = \sigma_k, \quad k = 1, \dots, r. \quad (10)$$

قرار می‌دهیم  $V = [V_1, V_2]$  که  $V_1$  و  $V_2$  در (۵) تعریف شده‌اند. آنگاه

$$U^T AV = U^T A[V_1, V_2] = U^T [AV_1, AV_2] = U^T [AV_1, \circ] = U^T [Av_1, Av_2, \dots, Av_r, \circ, \dots, \circ]$$

$$\begin{aligned} &= \begin{bmatrix} u_1^T \\ u_2^T \\ \vdots \\ u_r^T \\ \vdots \\ u_m^T \end{bmatrix} [Av_1, Av_2, \dots, Av_r, \circ, \dots, \circ] \\ &= \begin{bmatrix} u_1^T Av_1 & u_1^T Av_2 & \dots & u_1^T Av_r & \circ & \dots & \circ \\ u_2^T Av_1 & u_2^T Av_2 & \dots & u_2^T Av_r & \circ & \dots & \circ \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ u_r^T Av_1 & u_r^T Av_2 & \dots & u_r^T Av_r & \circ & \dots & \circ \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ u_m^T Av_1 & u_m^T Av_2 & \dots & u_m^T Av_r & \circ & \dots & \circ \end{bmatrix} \end{aligned}$$

يعنى

$$U^T AV = \begin{bmatrix} u_1^T Av_1 & u_1^T Av_2 & \dots & u_1^T Av_r & \circ & \dots & \circ \\ u_2^T Av_1 & u_2^T Av_2 & \dots & u_2^T Av_r & \circ & \dots & \circ \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ u_r^T Av_1 & u_r^T Av_2 & \dots & u_r^T Av_r & \circ & \dots & \circ \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ u_m^T Av_1 & u_m^T Av_2 & \dots & u_m^T Av_r & \circ & \dots & \circ \end{bmatrix} \quad (11)$$

اکنون از روابط (۱۰) و رابطه (۱۱) داریم

$$U^T AV = \begin{bmatrix} \sigma_1 & \circ & \dots & \circ & \circ & \dots & \circ \\ \circ & \sigma_2 & \dots & \circ & \circ & \dots & \circ \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \vdots \\ \circ & \circ & \dots & \sigma_r & \circ & \dots & \circ \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \circ & \circ & \dots & \circ & \circ & \dots & \circ \end{bmatrix} = \begin{bmatrix} \Sigma_1 & \circ \\ \circ & \circ \end{bmatrix} = \Sigma$$

که در آن  $(\Sigma_1, \dots, \sigma_r)$  داریم  $U^T AV = \Sigma$ . حال از  $\Sigma_1 = \text{diag}(\sigma_1, \dots, \sigma_r)$  داریم

$$UU^T AVV^T = U\Sigma V^T \implies A = U\Sigma V^T$$

و این اثبات را کامل می کند.

## نکته ۷.۱

برای ماتریس های وارون پذیر  $C$ ,  $B$ ,  $A$  و ماتریس دلخواه  $A$  داریم

$$\text{Rank}(BAC) = \text{Rank}(A)$$

به عبارتی اگر ماتریس های وارون پذیر از سمت چپ و راست در یک ماتریس ضرب شوند تاثیری در رتبه ای آن ندارند.

## نکته ۷.۲

رتبه ماتریس  $A$  برابر با  $r$  است زیرا ماتریس های  $U$  و  $V$  در تجزیه مقدار تکین  $A$  وارون پذیرند پس طبق نکته ای قبل داریم

$$\text{Rank}(A) = \text{Rank}(U\Sigma V^T) = \text{Rank}(\Sigma) = r$$

## تعريف ۷.۱

عناصر قطری ماتریس  $\Sigma$  مقادیر تکین ماتریس  $A$  نامیده می شوند. اعداد  $\sigma_1, \sigma_2, \dots, \sigma_r$  مقادیر تکین مثبت  $A$  هستند.

## ۷.۲ تعریف

ستون‌های  $U$  بردارهای تکین چپ و ستون‌های  $V$  بردارهای تکین راست نامیده می‌شوند.

### ۱.۱ منحصر به فرد بودن تجزیه مقدار تکین

طبق قضیه‌ی قبیل به تعداد  $k = \min\{m, n\}$  مقدار تکین (که می‌توانند صفر یا مثبت باشند) برای ماتریس  $A$  وجود دارد. فرض کنید رتبه  $A$  برابر  $r$  باشد. پس  $r$  مقدار تکین مثبت وجود دارد. این‌ها ریشه‌های دوم مثبت مقادیر ویژه مخالف صفر  $AA^T$  یا  $A^T A$  هستند. بقیه  $(k - r)$  مقدار تکین، اگر  $k < r$  صفر هستند. بنابراین مقادیر تکین منحصر به فرد هستند ولیکن بردارهای تکین منحصر به فرد نیستند. توجه کنید برای ماتریس‌های رتبه کامل داریم  $\{m, n\} = \min\{m, n\}$  که در این حالت از نتیجه می‌شود  $k = \min\{m, n\}$ .

## ۷.۱ مثال

مقادیر تکین ماتریس داده شده را بیابید.

$$A = \begin{bmatrix} -5 & 1 \\ 8 & 0 \\ 4 & -7 \end{bmatrix}, \quad m = 3, \quad n = 2$$

حل: طبق تعریف مقادیر تکین  $A$  ریشه‌های مقادیر ویژه  $AA^T$  یا  $A^T A$  هستند پس ابتدا مقادیر ویژه  $AA^T$  یا  $A^T A$  را باید بیابیم. داریم

$$AA^T = \begin{bmatrix} 26 & -40 & -27 \\ -40 & 64 & 32 \\ -27 & 32 & 65 \end{bmatrix}$$

$$A^T A = \begin{bmatrix} 105 & -33 \\ -33 & 50 \end{bmatrix}$$

اما مقادیر ویژه‌ی دو ماتریس  $AA^T$  و  $A^T A$  یکی هستند و تنها در مقادیر ویژه صفر تفاوت دارند. لذا منطقی است که مقادیر ویژه‌ی ماتریس  $A^T A$  که از لحاظ ابعاد از  $AA^T$  کوچکتر است را محاسبه کنیم.

هر چند در این مثال مقادیر ویژه‌ی هر دو ماتریس را به دست می‌آوریم اما در مثال‌های بعد ازین دو ماتریس  $A$  و  $A^T A$  به محاسبه‌ی مقادیر ویژه‌ی آن که اندازه‌ی کوچکتری دارد می‌پردازیم.

چندجمله‌ای ویژه  $AA^T$  برابر است با

$$\lambda^3 - 155\lambda^2 + 4161\lambda$$

که دارای ریشه‌های زیر است

$$\lambda_1 = 120/4564, \quad \lambda_2 = 34/5436, \quad \lambda_3 = 0$$

به علاوه چندجمله‌ای ویژه  $A^T A$  برابر است با

$$\lambda^2 - 155\lambda + 4161$$

که دارای ریشه‌های زیر است

$$\lambda_1 = 120/4564, \quad \lambda_2 = 34/5436$$

همانطور که می‌بینید ریشه‌های این دو چندجمله‌ای یکی‌اند و تنها اولی یک ریشه‌ی صفر دیگر دارد (چون ابعادش یک واحد بیشتر است). بنابراین مقادیر تکین  $A$  برابرند با

$$\sigma_1 = \sqrt{\lambda_1} = \sqrt{120/4564} = 10/9753$$

$$\sigma_2 = \sqrt{\lambda_2} = \sqrt{34/5436} = 5/8774$$

توجه کنید که  $2 = k = \min\{m, n\} = \min\{3, 2\} = 2$  مقدار تکین مثبت وجود دارد.  
به علاوه مطابق قضیه تعداد مقادیر تکین مثبت برابر رتبه  $A$  است پس در اینجا رتبه  $A$  برابر ۲ خواهد بود.

### مثال ۷.۲

مقادیر تکین ماتریس داده شده را بیابید.

$$A = \begin{bmatrix} 2 & -2 & 1 \\ 2 & 1 & 2 \end{bmatrix}, \quad m = 2, \quad n = 3$$

حل: چون  $A^T A$  ماتریسی  $3 \times 3$  و  $AA^T$  ماتریسی  $2 \times 2$  است پس منطقی است که جذر مقادیر ویژه ماتریس  $AA^T$  را بیابیم.

$$AA^T = \begin{bmatrix} 9 & 5 \\ 5 & 14 \end{bmatrix} \rightarrow P(\lambda) = \lambda^2 - 23\lambda + 101$$

ریشه‌های چندجمله‌ای فوق به صورت

$$\lambda_1 = 17/0902, \quad \lambda_2 = 5/9098$$

هستند و از آنجا

$$\sigma_1 = \sqrt{\lambda_1} = \sqrt{17/0902} = 4/1340$$

$$\sigma_2 = \sqrt{\lambda_2} = \sqrt{5/9098} = 2/4310$$

مقادیر تکین  $A$  هستند. توجه کنید مطابق قضیه تعداد مقادیر تکین مثبت برابر رتبه  $A$  است پس در اینجا رتبه  $A$  برابر ۲ خواهد بود.

### مثال ۷.۳

با محاسبه‌ی تعداد مقادیر تکین مثبت  $A$  رتبه‌ی آن را تعیین کنید.

$$A = \begin{bmatrix} 1 & 1 & 5 & 0 \\ 3 & 3 & 6 & 1 \\ -2 & -2 & 7 & -1 \end{bmatrix}, \quad m = 3, \quad n = 4$$

حل: به تعداد  $3 = k = \min\{m, n\} = \min\{3, 4\} = 3$  مقدار تکین داریم. مانند استدلال مثال‌های قبلی ماتریس  $AA^T$  را در نظر می‌گیریم.

$$AA^T = \begin{bmatrix} 27 & 36 & 31 \\ 36 & 55 & 29 \\ 31 & 29 & 58 \end{bmatrix}$$

چندجمله‌ای مشخصه این ماتریس چنین است:

$$P(\lambda) = \lambda^3 - 140\lambda^2 + 3143\lambda - 128$$

واضح است که صفر ریشه‌ی این چندجمله‌ای نیست زیرا  $P(0) = 0$  نمی‌تواند برقرار باشد پس چندجمله‌ای فوق سه ریشه‌ی ناصلفر دارد پس رتبه‌ی  $A$  برابر ۳ است. این را می‌توان با محاسبه‌ی ریشه‌ها نیز بررسی نمود (اگرچه در اینجا نیازی نمی‌باشد)

$$\lambda_1 = 111/9302, \quad \lambda_2 = 28/0290, \quad \lambda_3 = 0/0408$$

و از آن داریم:

$$\sigma_1 = \sqrt{\lambda_1} = 10/5797, \quad \sigma_2 = \sqrt{\lambda_2} = 5/2942, \quad \sigma_3 = \sqrt{\lambda_3} = 0/2020$$

لذا سه مقدار تکین مثبت داریم پس رتبه  $A$  برابر ۳ است.

## ۲ محاسبه‌ی تجزیه مقادیر منفرد

قضیه‌ی قبل علاوه بر اثبات وجود تجزیه  $SVD$  نحوه‌ی محاسبه‌ی آن را نیز بیان می‌کند که به صورت زیر می‌باشد ( $r$  برابر با تعداد مقادیر تکین مثبت است)

گام ۱: ماتریس  $A^T A$  را تشکیل دهید و جذر مقادیر ویژه‌ی آن را با  $\sigma_i$  ها نمایش دهید:

$$\sigma_1 = \sqrt{\lambda_1}, \quad \dots, \quad \sigma_r = \sqrt{\lambda_r}, \quad \sigma_{r+1} = \dots = \sigma_n = 0$$

قرار می‌دهیم (مقادیر تکین به صورت نزولی در ماتریس  $\Sigma$  قرار گرفته‌اند)

$$\Sigma_1 = \begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_r \end{bmatrix}_{r \times r}, \quad \Sigma = \begin{bmatrix} \Sigma_1 & 0 \\ 0 & 0 \end{bmatrix}_{m \times n}$$

گام ۲: بردارهای ویژه‌ی که شده‌ی  $A^T A$  را با  $v_1, v_2, \dots, v_n$  نمایش داده و ماتریس  $V$  را به صورت زیر تشکیل دهید:

$$V = [v_1, v_2, \dots, v_n]$$

گام ۳: برای  $i = 1, 2, \dots, r$  بردارهای  $u_i$  را به صورت زیر می‌سازیم:

$$u_i = \frac{1}{\sigma_i} A v_i$$

گام ۴: بردارهای  $u_m, u_{r+1}, u_{r+2}, \dots, u_m$  را طوری به دست می‌آوریم که ماتریس

$$U = [u_1, u_2, \dots, u_r, u_{r+1}, u_{r+2}, \dots, u_m]$$

متعامد باشد (توجه شود که در این گام می‌توان از الگوریتم گرام اشمیت بهره برد که در مثال‌ها با نحوه‌ی بکارگیری آن آشنا می‌شویم).

گام ۵: ماتریس‌های  $V, \Sigma, U$  تشکیل شده‌اند لذا تجزیه  $SVD$  ماتریس  $A$  به صورت زیر خواهد بود.

$$A = U \Sigma V^T$$

#### مثال ۷.۴

تجزیه  $SVD$  ماتریس داده شده را بیابید (محاسبات با  $4$  رقم بعد از اعشار انجام شود).

$$A = \begin{bmatrix} -1 & 0 & 2 \\ 1 & 2 & -2 \end{bmatrix} \quad m = 2, \quad n = 3$$

حل: گام ۱ :

$$A^T A = \begin{bmatrix} 2 & 2 & -4 \\ 2 & 4 & -4 \\ -4 & -4 & 8 \end{bmatrix}$$

$$\lambda_1 = 12/3852, \quad \lambda_2 = 1/8148, \quad \lambda_3 = 0$$

پس  $r = 2$  لذا

$$\sigma_1 = \sqrt{\lambda_1} = 3/5193, \quad \sigma_2 = \sqrt{\lambda_2} = 1/2708, \quad \sigma_3 = \sqrt{\lambda_3} = 0$$

ماتریس  $2 \times 2$ ،  $\Sigma_1$  را تشکیل می‌دهیم :

$$\Sigma_1 = \begin{bmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{bmatrix} = \begin{bmatrix} 3/5193 & 0 \\ 0 & 1/2708 \end{bmatrix}$$

حال ماتریس  $3 \times 2$ ،  $\Sigma$  را تشکیل می‌دهیم :

$$\Sigma = \begin{bmatrix} \Sigma_1 & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 3/5193 & 0 & 0 \\ 0 & 1/2708 & 0 \end{bmatrix}_{2 \times 3}$$

گام ۲ : بردارهای ویژه متناظر با  $\lambda_i$  ها را می‌یابیم (با توجه به اینکه در فصل‌های قبل با نحوه محاسبه بردارهای ویژه آشنا شده‌اید در اینجا از محاسبات مربوط به بردارهای ویژه صرف نظر شده است).

$$\lambda_1 = 12/3852 \rightarrow v_1 = \begin{bmatrix} -0/3946 \\ -0/4706 \\ 0/7892 \end{bmatrix}$$

$$\lambda_2 = 1/8148 \rightarrow v_2 = \begin{bmatrix} -0/2105 \\ 0/8824 \\ 0/4209 \end{bmatrix}$$

$$\lambda_3 = 0 \rightarrow v_3 = \begin{bmatrix} -0/8944 \\ 0 \\ -0/4472 \end{bmatrix}$$

توجه کنید که بردارهای ویژه متناظر با  $\lambda_i$  ها یکه شده‌اند (یعنی بر نرم ۲ خود تقسیم شده‌اند)  
حال ماتریس  $V$  را به صورت زیر می‌سازیم :

$$V = [v_1, v_2, v_3] = \begin{bmatrix} -0/3946 & -0/2105 & -0/8944 \\ -0/4706 & 0/8824 & 0 \\ 0/7892 & 0/4209 & -0/4472 \end{bmatrix}$$

گام ۳ : برای  $i = ۱, ۲$  بردارهای  $u_1, u_2$  را به صورت زیر به دست می آوریم :

$$u_1 = \frac{1}{\sigma_1} Av_1 = \frac{1}{3/5193} \begin{bmatrix} -1 & 0 & 2 \\ 1 & 2 & -2 \end{bmatrix} \begin{bmatrix} -0/3946 \\ -0/4706 \\ 0/7892 \end{bmatrix} = \begin{bmatrix} 0/5606 \\ -0/8281 \\ 0/8281 \end{bmatrix}$$

$$u_2 = \frac{1}{\sigma_2} Av_2 = \frac{1}{1/2708} \begin{bmatrix} -1 & 0 & 2 \\ 1 & 2 & -2 \end{bmatrix} \begin{bmatrix} -0/2105 \\ 0/8824 \\ 0/4209 \end{bmatrix} = \begin{bmatrix} 0/8281 \\ 0/5606 \\ 0/4209 \end{bmatrix}$$

توجه کنید که مطابق اثبات قضیه بردارهای  $u_1, u_2$  یکه‌اند. همچنین  $U$  ماتریسی  $2 \times m = 2 \times 2$  می‌باشد که در اینجا دو ستون  $U$  ساخته شده‌اند لذا نیازی به اضافه کردن بردار به ماتریس  $U$  با کمک الگوریتم گرام-اشمیت نداریم، یعنی عملأً نیازی به گام چهارم نیست. پس :

$$U = [u_1, u_2] = \begin{bmatrix} 0/5606 & 0/8281 \\ -0/8281 & 0/5606 \end{bmatrix}$$

مطابق اثبات قضیه،  $u_1, u_2$  متعامد یکه‌اند پس ماتریس  $U$  متعامد خواهد بود.

گام ۵ : تجزیه  $SVD$  ماتریس  $A$  کامل شده‌است و داریم :

$$A = \begin{bmatrix} -1 & 0 & 2 \\ 1 & 2 & -2 \end{bmatrix} = U \Sigma V^T =$$

$$\begin{bmatrix} 0/5606 & 0/8281 \\ -0/8281 & 0/5606 \end{bmatrix} \begin{bmatrix} 3/5193 & 0 & 0 \\ 0 & 1/2708 & 0 \end{bmatrix} \begin{bmatrix} -0/3946 & -0/2105 & -0/8944 \\ -0/4706 & 0/8824 & 0 \\ 0/7892 & 0/4209 & -0/4472 \end{bmatrix}^T$$

=

$$\begin{bmatrix} 0/5606 & 0/8281 \\ -0/8281 & 0/5606 \end{bmatrix} \begin{bmatrix} 3/5193 & 0 & 0 \\ 0 & 1/2708 & 0 \end{bmatrix} \begin{bmatrix} -0/3946 & -0/4706 & 0/7892 \\ -0/2105 & 0/8824 & 0/4209 \\ -0/8944 & 0 & -0/4472 \end{bmatrix}$$

مثال ۷.۵

تجزیه  $SVD$  ماتریس داده شده را محاسبه کنید.

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 1 & 2 & 3 \end{bmatrix} \quad m = 2, \quad n = 3$$

حل: گام ۱ :

$$A^T A = \begin{bmatrix} 2 & 4 & 6 \\ 4 & 8 & 12 \\ 6 & 12 & 18 \end{bmatrix}$$

مقادیر ویژه این ماتریس چنین‌اند :

$$\lambda_1 = 28, \quad \lambda_2 = 0, \quad \lambda_3 = 0$$

پس  $r = 1$  لذا

$$\sigma_1 = \sqrt{\lambda_1} = \sqrt{28} = 5/2915, \quad \sigma_2 = \sigma_3 = 0$$

حال ماتریس  $1 \times 1$ ،  $\Sigma$  را تشکیل می‌دهیم:

$$\Sigma_1 = [\sigma_1] = [5/2915]$$

برای ماتریس  $3 \times 2$ ،  $\Sigma$  خواهیم داشت:

$$\Sigma = \begin{bmatrix} \Sigma_1 & \cdot \\ \cdot & \cdot \end{bmatrix} = \begin{bmatrix} 5/2915 & \cdot & \cdot \\ \cdot & \cdot & \cdot \end{bmatrix}_{2 \times 3}$$

گام ۲: بردارهای ویژه  $A^T A$  به صورت زیر می‌باشند:

$$\lambda_1 = 28 \longrightarrow v_1 = [0/2673, 0/5345, 0/8018]^T$$

$$\lambda_2 = 0 \longrightarrow v_2 = [0/3586, 0/7171, -0/5976]^T$$

$$\lambda_3 = 0 \longrightarrow v_3 = [0/8944, -0/4472, 0]^T$$

لذا ماتریس  $V$  به صورت زیر حاصل می‌گردد:

$$V = [v_1, v_2, v_3] = \begin{bmatrix} 0/2673 & 0/3586 & 0/8944 \\ 0/5345 & 0/7171 & -0/4472 \\ 0/8018 & -0/5976 & 0 \end{bmatrix}$$

گام ۳: برای  $r = 1, \dots, r$  یعنی تنها  $i = 1$  (زیرا  $r = 1$ ) داریم:

$$u_1 = \frac{1}{\sigma_1} A v_1 = \frac{1}{5/2915} \begin{bmatrix} 1 & 2 & 3 \\ 1 & 2 & 3 \\ 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 0/2673 \\ 0/5345 \\ 0/8018 \end{bmatrix} = \begin{bmatrix} 0/7071 \\ 0/7071 \\ 0/7071 \end{bmatrix}$$

توجه گردد که مطابق اثبات قضیه  $u_1$  یکه می‌باشد. ماتریس  $U = [u_1, u_2] = U$  است و در اینجا تنها یک ستون از  $U$  ساخته شده، پس لازم است ستون دیگر را با استفاده از الگوریتم گرام اشمیت بسازیم.

در اینجا  $u_1$  موجود است باید  $u_2$  را به قسمی تولید کنیم که ماتریس  $U = [u_1, u_2]$  متعامد باشد. فرض کنیم  $\tilde{u}_2$  یک بردار دلخواه است به قسمی که مجموعه  $\{u_1, \tilde{u}_2\}$  مستقل خطی باشد. آنگاه با اعمال الگوریتم گرام-اشمیت بر این مجموعه می‌توان مجموعه جدید  $\{u_1, u_2\}$  را طوری ساخت که یک مجموعه متعامد یکه باشد. در اینصورت حتما  $U = [u_1, u_2]$  ماتریسی متعامد خواهد بود.

توجه کنید چون  $u_1$  یکه است پس با اعمال روش گرام-اشمیت بر  $\{u_1, \tilde{u}_2\}$ ، بردار  $u_1$  تغییری نخواهد کرد و تنها  $\tilde{u}_2$  تغییر می‌کند. اما  $\tilde{u}_2$  چه می‌تواند باشد؟ در واقع  $\tilde{u}_2$  هرچه می‌تواند باشد به شرطی که  $\{u_1, \tilde{u}_2\}$  مستقل خطی باشد.

در اینجا با انتخاب  $\tilde{u}_2 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$  (به صورت دلخواه انتخاب می‌کنیم) واضح است که مجموعه

$$\{u_1, \tilde{u}_2\} = \left\{ \begin{bmatrix} 0/7071 \\ 0/7071 \\ 0/7071 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \right\}$$

مستقل خطی است. توجه کنید هر انتخاب دیگری برای  $\tilde{u}_2$  به شرطی که مجموعه  $\{u_1, \tilde{u}_2\}$  مستقل خطی باشد اشکالی در ادامه ی کار بوجود نمی‌آورد. با اعمال الگوریتم گرام اشمیت بر این مجموعه به مجموعه جدید زیر می‌رسیم که متعامد یکه است (براحتی می‌توان بررسی کرد)

$$\{u_1, u_2\} = \left\{ \begin{bmatrix} \circ / 7071 \\ \circ / 7071 \end{bmatrix}, \begin{bmatrix} \circ / 7071 \\ -\circ / 7071 \end{bmatrix} \right\}$$

در نتیجه ماتریس  $U$  به شکل زیر خواهد بود:

$$U = [u_1, u_2] = \begin{bmatrix} \circ / 7071 & \circ / 7071 \\ \circ / 7071 & -\circ / 7071 \end{bmatrix}$$

گام ۵: اکنون ماتریس‌های  $V, \Sigma, U$  مشخص شده‌اند لذا داریم:

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 1 & 2 & 3 \end{bmatrix} = U \Sigma V^T =$$

$$\begin{bmatrix} \circ / 7071 & \circ / 7071 \\ \circ / 7071 & -\circ / 7071 \end{bmatrix} \begin{bmatrix} 5/2915 & \circ & \circ \\ \circ & \circ & \circ \end{bmatrix} \begin{bmatrix} \circ / 2673 & \circ / 3586 & \circ / 8944 \\ \circ / 5345 & \circ / 7171 & -\circ / 4472 \\ \circ / 8018 & -\circ / 5976 & \circ \end{bmatrix}^T$$

لذا

$$A = \begin{bmatrix} \circ / 7071 & \circ / 7071 \\ \circ / 7071 & -\circ / 7071 \end{bmatrix} \begin{bmatrix} 5/2915 & \circ & \circ \\ \circ & \circ & \circ \end{bmatrix} \begin{bmatrix} \circ / 2673 & \circ / 5345 & \circ / 8018 \\ \circ / 3586 & \circ / 7171 & -\circ / 5976 \\ \circ / 8944 & -\circ / 4472 & \circ \end{bmatrix}$$

### مثال ۷.۶

تجزیه SVD ماتریس زیر را محاسبه کنید.

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 3 \\ -3 & 4 \end{bmatrix}, \quad m = 3, \quad n = 2$$

حل: گام ۱: ماتریس  $A^T A$  را تشکیل می‌دهیم:

$$A^T A = \begin{bmatrix} 14 & -4 \\ -4 & 29 \end{bmatrix}$$

برای مقادیر ویژه این ماتریس داریم:

$$\lambda_1 = 30, \quad \lambda_2 = 13$$

بنابراین  $r = 2$  داریم:

$$\sigma_1 = \sqrt{\lambda_1} = \sqrt{30} = 5/\sqrt{772}, \quad \sigma_2 = \sqrt{\lambda_2} = \sqrt{13} = 3/\sqrt{6056}$$

به علاوه  $\Sigma_1$  ماتریسی  $2 \times 2$  است که

$$\Sigma_1 = \begin{bmatrix} \sigma_1 & \circ \\ \circ & \sigma_2 \end{bmatrix} = \begin{bmatrix} 5/\sqrt{772} & \circ \\ \circ & 3/\sqrt{6056} \end{bmatrix}$$

و  $\Sigma$  ماتریسی  $2 \times 3$  به صورت زیر است:

$$\Sigma = \begin{bmatrix} \Sigma_1 & \circ \\ \circ & \circ \end{bmatrix} = \begin{bmatrix} 5/\sqrt{772} & \circ & \circ \\ \circ & 3/\sqrt{6056} & \circ \end{bmatrix}$$

گام ۲: بردارهای ویژه متناظر با  $\lambda_1 = 30$ ،  $\lambda_2 = 13$  را به دست می‌آوریم:

$$\lambda_1 = 30 \rightarrow v_1 = [-\frac{1}{2425}, \frac{1}{9701}]^T$$

$$\lambda_2 = 13 \rightarrow v_2 = [-\frac{1}{9701}, -\frac{1}{2425}]^T$$

لذا ماتریس  $V$  چنین خواهد بود:

$$V = [v_1, v_2] = \begin{bmatrix} -\frac{1}{2425} & -\frac{1}{9701} \\ \frac{1}{9701} & -\frac{1}{2425} \end{bmatrix}$$

گام ۳: برای  $i = 1, 2$  بردارهای  $u_i$  را به دست می‌آوریم:

$$u_1 = \frac{1}{\sigma_1} Av_1 = \frac{1}{5/4772} \begin{bmatrix} 1 & 2 \\ 2 & 3 \\ -3 & 4 \end{bmatrix} \begin{bmatrix} -\frac{1}{2425} \\ \frac{1}{9701} \end{bmatrix} = \begin{bmatrix} \frac{1}{3100} \\ \frac{1}{4428} \\ \frac{1}{8413} \end{bmatrix}$$

$$u_2 = \frac{1}{\sigma_2} Av_2 = \frac{1}{3/6056} \begin{bmatrix} 1 & 2 \\ 2 & 3 \\ -3 & 4 \end{bmatrix} \begin{bmatrix} -\frac{1}{9701} \\ -\frac{1}{2425} \end{bmatrix} = \begin{bmatrix} -\frac{1}{4036} \\ -\frac{1}{7399} \\ \frac{1}{5381} \end{bmatrix}$$

گام ۴: همانطور که مشاهده می‌گردد  $U$  ماتریسی  $3 \times 3 = m \times m$  می‌باشد در حالی که تنها دو ستون از آن را محاسبه کرده‌ایم. لذا می‌بایست با استفاده از الگوریتم گرام-اشمیت یک ستون دیگر برای  $U$  پیدا کنیم. فرض کنید  $\tilde{u}_3$  به صورت

$$\tilde{u}_3 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \quad (\text{به صورت دلخواه انتخاب می‌کنیم}) \quad \text{باشد.}$$

توجه کنید هر انتخاب دیگر به شرطی که مجموعه  $\{u_1, u_2, \tilde{u}_3\}$  مستقل خطی باشد قابل قبول است.

می‌خواهیم مجموعه  $\{u_1, u_2, \tilde{u}_3\}$  را به یک مجموعه یکا متعامد  $\{u_1, u_2, u_3\}$  تبدیل کنیم. که در اینصورت ماتریس متعامد  $U = [u_1, u_2, u_3]$  به دست خواهد آمد.

توجه کنید از آنجایی که  $\{u_1, u_2\}$  مجموعه‌ای یکه متعامد است (مطابق اثبات قضیه) پس وقتی الگوریتم گرام-اشمیت بر مجموعه  $\{u_1, u_2, \tilde{u}_3\}$  اعمال شود بردارهای  $u_1, u_2, u_3$  دچار تغییر نخواهند شد و تنها  $\tilde{u}_3$  تغییر می‌کند که آن را می‌نامیم.

اکنون الگوریتم گرام-اشمیت را بر مجموعه زیر اعمال می‌کنیم:

$$\{u_1, u_2, \tilde{u}_3\} = \left\{ \begin{bmatrix} \frac{1}{3100} \\ \frac{1}{4428} \\ \frac{1}{8413} \end{bmatrix}, \begin{bmatrix} -\frac{1}{4036} \\ -\frac{1}{7399} \\ \frac{1}{5381} \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \right\}$$

لذا به مجموعه یکه زیر می‌رسیم:

$$\{u_1, u_2, u_3\} = \left\{ \begin{bmatrix} \frac{1}{3100} \\ \frac{1}{4428} \\ \frac{1}{8413} \end{bmatrix}, \begin{bmatrix} -\frac{1}{4036} \\ -\frac{1}{7399} \\ \frac{1}{5381} \end{bmatrix}, \begin{bmatrix} \frac{1}{8608} \\ -\frac{1}{5064} \\ -\frac{1}{0507} \end{bmatrix} \right\}$$

بنابراین ماتریس  $U$  به صورت زیر به دست می‌آید:

$$U = [u_1, u_2, u_3] = \begin{bmatrix} 0/3100 & -0/4030 & 0/8608 \\ 0/4428 & -0/7399 & -0/5064 \\ 0/8413 & 0/5381 & -0/0507 \end{bmatrix}$$

گام ۵ : اکنون عامل‌های تجزیه  $SVD$  به طور کامل مشخص شده‌اند :

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 3 \\ -3 & 4 \end{bmatrix} = U\Sigma V^T =$$

$$\begin{bmatrix} 0/3100 & -0/4030 & 0/8608 \\ 0/4428 & -0/7399 & -0/5064 \\ 0/8413 & 0/5381 & -0/0507 \end{bmatrix} \begin{bmatrix} 5/47772 & 0 & 0 \\ 0 & 3/6056 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} -0/2425 & -0/9701 & -0/2425 \\ 0/9701 & -0/2425 & 0/9701 \end{bmatrix}^T$$

مشاهده می‌شود که ماتریس داده شده به صورت خواسته شده تجزیه گردیده است.

## ۷.۱ تذکر

همانطور که قبلاً دیدید جهت محاسبه‌ی تجزیه  $SVD$  ماتریس مستطیلی  $A$  با استفاده از قضیه‌ی قبل در هنگامی که رتبه  $A$  برابر  $r$  است تنها  $r$  ستون از  $m$  ستون ماتریس  $U$  ساخته می‌شود و بنا بر این نیاز است  $m-r$  ستون دیگر  $U$  را از طریق الگوریتم گرام-اشمیت تولید کنیم. البته حالت خاصی هم رخ می‌دهد که نیاز نیست از الگوریتم گرام-اشمیت استفاده شود، در واقع وقتی که  $r = m$  یا  $m = r$  با توجه به اینکه  $r = \text{Rank}(A) \leq \min\{m, n\}$  اینجا می‌گیریم که اگر  $A$  ماتریسی با  $n \leq m$  و رتبه کامل باشد آنگاه  $r = m$  و لذا استفاده از فرآیند فوق نیازی به استفاده از الگوریتم گرام-اشمیت ندارد. اما اگر  $A$  ماتریسی با  $m > n$  باشد آنگاه از

$$r = \text{Rank}(A) \leq \min\{m, n\} = n < m$$

مشاهده می‌شود که  $r < m$  و لذا  $m - r \neq r$ . در این حالت  $m - r > 0$  یعنی حتماً در محاسبه‌ی ستون‌های  $U$  باید از الگوریتم گرام-اشمیت استفاده شود تا  $m - r \neq 0$  ستون دیگر  $U$  را محاسبه کنیم.

## ۷.۲ قضیه

فرض کنید تجزیه  $SVD$  ماتریس  $A \in \mathbb{R}^{m \times n}$  به صورت  $A = U\Sigma V^T$  باشد آنگاه

$$AA^T U = U \tilde{\Sigma}, \quad A^T A V = V \hat{\Sigma}$$

که در آن  $\tilde{\Sigma}$  ماتریس  $m \times m$  است به طوری که

$$\tilde{\Sigma} = \begin{bmatrix} \tilde{\Sigma}_1 & \circ \\ \circ & \circ \end{bmatrix}$$

و  $\hat{\Sigma}$  ماتریسی  $n \times n$  است به قسمی که

$$\hat{\Sigma} = \begin{bmatrix} \hat{\Sigma}_1 & \circ \\ \circ & \circ \end{bmatrix}$$

و  $\tilde{\Sigma}_1$  ماتریسی قطری به صورت  $\tilde{\Sigma}_1 = \text{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_s^2)$  با  $s = \min\{m, n\}$  است.

اثبات: در اینجا تساوی  $AA^T U = U \tilde{\Sigma}$  را اثبات کرده و اثبات تساوی دیگر به عنوان تمرین رها می‌شود:

$$\begin{aligned} AA^T U &= (U \Sigma V^T)(U \Sigma V^T)^T U = (U \Sigma V^T)(V \Sigma^T U^T)U \\ &= (U \Sigma)(V^T V)(\Sigma^T)(U^T U) = (U \Sigma)(I)(\Sigma^T)(I) \quad (\text{زیرا } V, U \text{ متعامدند}) \end{aligned}$$

$$= U \Sigma \Sigma^T = U \tilde{\Sigma}$$

که  $\tilde{\Sigma}$  ماتریسی  $m \times m$  تعریف شده در بالا است و این اثبات را تکمیل می‌کند.  
اکنون طبق معادلات زیر

$$(AA^T)U = U \tilde{\Sigma} \quad (A^T A)V = V \hat{\Sigma}$$

از قضیه‌ی قبل می‌توان دریافت که

$$(AA^T)u_i = \sigma_i^2 u_i, \quad i = 1, 2, \dots, m$$

$$(A^T A)v_i = \sigma_i^2 v_i, \quad i = 1, 2, \dots, n$$

و این یعنی  $u_i$  ها همان بردارهای ویژه ماتریس  $AA^T$  و  $v_i$  ها همان بردارهای ویژه ماتریس  $A^T A$  هستند. بعلاوه  $\sigma_i$  ها مقادیر ویژه ماتریس  $A^T A$  یا  $AA^T$  می‌باشند که مقادیری نامنفی هستند.

### ۳ حل دستگاه‌های خطی مربعی و غیرمربعی با تجزیه مقادیر تکین

#### ۱. حل دستگاه مربعی $AX = b$

فرض کنید تجزیه مقادیر تکین ماتریس مربعی وارون پذیر  $A \in \mathbb{R}^{n \times n}$  به صورت  $A = U \Sigma V^T$  که  $U$  و  $\Sigma$  و  $V$  ماتریس هایی  $n \times n$  هستند موجود است. به عنوان یک استفاده فرعی از این تجزیه می‌توان دستگاه  $AX = b$  را به شکلی که در ادامه آورده می‌شود حل نمود:

$$AX = b \rightarrow U \Sigma V^T X = b \quad (12)$$

با ضرب طرفین رابطه (12) از سمت چپ در  $U^T$  و استفاده از این حقیقت که  $U^T U = I$  داریم

$$U^T U \Sigma V^T X = U^T b \Rightarrow \Sigma V^T X = U^T b \quad (13)$$

حال فرض کنید  $V^T X = Z$  پس داریم  $Z = U^T b$  و  $\Sigma Z = U^T b$  و چون  $\Sigma$  ماتریسی قطری است به راحتی می‌توان  $Z$  را به صورت زیر محاسبه نمود.

$$Z = \Sigma^{-1} U^T b \quad (14)$$

اکنون از  $Z = \Sigma^{-1} U^T b$  و از رابطه (14) داریم

$$X = VZ = V\Sigma^{-1}U^T b$$

یا

$$X = V\Sigma^{-1}U^T b$$

که یک فرم بسته برای جواب دستگاه  $AX = b$  خواهد بود.

### مثال ۷.۷

جواب دستگاه داده شده را با استفاده از تجزیه SVD ماتریس ضرایب پیدا کنید.

$$\begin{bmatrix} 1 & 2 & 3 \\ 2 & 1 & 2 \\ 2 & 3 & 1 \end{bmatrix} X = \begin{bmatrix} 10 \\ 13 \\ 13 \end{bmatrix}$$

حل: عامل‌های تجزیه مقادیر تکین  $A$  چنین‌اند (بررسی جزییات محاسبات به عهده‌ی خواننده است)

$$U = \begin{bmatrix} -0/5774 & -0/4082 & 0/7071 \\ -0/5774 & -0/4082 & -0/7071 \\ -0/5774 & 0/8165 & 0/0000 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 6/0000 & 0 & 0 \\ 0 & 1/7321 & 0 \\ 0 & 0 & 1/7321 \end{bmatrix}$$

$$V = \begin{bmatrix} -0/5774 & 0 & -0/8165 \\ -0/5774 & 0/7071 & 0/4082 \\ -0/5774 & -0/7071 & 0/4082 \end{bmatrix}$$

بنابراین

$$X = V\Sigma^{-1}U^T b = \begin{bmatrix} 3/0000 \\ 2/0000 \\ 1/0000 \end{bmatrix}$$

### مثال ۷.۸

جواب دستگاه داده شده را با استفاده از تجزیه SVD ماتریس ضرایب پیدا کنید.

$$\begin{bmatrix} 7 & 2 & -3 & 1 \\ 1 & 4 & -4 & 0 \\ -2 & -1 & -3 & 6 \\ -5 & -5 & 0 & 1 \end{bmatrix} X = \begin{bmatrix} 22 \\ 7 \\ -11 \\ -25 \end{bmatrix}$$

حل: عامل‌های تجزیه SVD ماتریس ضرایب به صورت زیرندا (به کمک نرم افزار متلب)

$$U = \begin{bmatrix} -0/6684 & -0/2386 & -0/5918 & 0/3822 \\ -0/3772 & -0/2967 & 0/7909 & 0/3797 \\ 0/1648 & -0/9032 & -0/0733 & -0/3894 \\ 0/6196 & -0/1979 & -0/1374 & 0/7471 \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} 10/9212 & 0 & 0 & 0 \\ 0 & 7/5038 & 0 & 0 \\ 0 & 0 & 4/0720 & 0 \\ 0 & 0 & 0 & 2/1995 \end{bmatrix}$$

$$V = \begin{bmatrix} -\circ/7767 & \circ/1104 & -\circ/6184 & \circ/0448 \\ -\circ/5593 & \circ/0304 & \circ/6729 & -\circ/4832 \\ \circ/2765 & \circ/6147 & -\circ/2868 & -\circ/6808 \\ \circ/0861 & -\circ/7804 & -\circ/2872 & -\circ/5487 \end{bmatrix}$$

$$X = V\Sigma^{-1}U^T b = \begin{bmatrix} 3/0000 \\ 2/0000 \\ 1/0000 \\ -\circ/0000 \end{bmatrix}$$

## ۷.۱ توجه

برای حل یک دستگاه این روش که ابتدا تجزیه مقادیر تکین ماتریس ضرایب را محاسبه کرده و سپس به کمک آنها دستگاه را حل کنیم مقرن به صرفه نیست بلکه اگر در مساله ای این تجزیه از قبل محاسبه شده باشد به عنوان یک استفاده‌ی فرعی می‌توان از آن برای حل دستگاه کمک گرفت.

## ۲. حل دستگاه فرامعین (جواب کمترین مربعات)

Solving the overdetermined linear system (The least square solution)  
قبل‌اً دیدیم که جواب کمترین مربعات دستگاه فرامعین

$$AX = b, \quad A \in \mathbb{R}^{m \times n}, \quad m > n; \quad X \in \mathbb{R}^n, \quad b \in \mathbb{R}^m$$

از حل دستگاه معادلات نرمال  $A^T AX = A^T b$  به دست می‌آید. فرض کنید  $A$  رتبه کامل و دارای تجزیه‌ی باشد. با قرار دادن این تجزیه در معادلات نرمال داریم:

$$(U\Sigma V^T)^T (U\Sigma V^T) X = (U\Sigma V^T)^T b$$

یا

$$V\Sigma^T \underbrace{U^T U}_{I} \Sigma V^T X = V\Sigma^T U^T b$$

یا

$$V\Sigma^T \Sigma V^T X = V\Sigma^T U^T b$$

با ضرب طرفین رابطه‌ی فوق از چپ در  $V^T V = I$  و اینکه  $V^T V = I$  داریم:

$$V^T V \Sigma^T \Sigma V^T X = V^T V \Sigma^T U^T b$$

یا

$$\Sigma^T \Sigma V^T X = \Sigma^T U^T b$$

حال فرض کنید  $X = V^T Y$  آنگاه  $Y = \Sigma^T U^T b$  و چون  $\Sigma^T \Sigma Y = \Sigma^T U^T b$  ماتریس قطری وارون پذیر است (از اینکه  $A$  رتبه کامل است) است دستگاه اخیر برای قابل حل است:

$$Y = (\Sigma^T \Sigma)^{-1} \Sigma^T U^T b$$

از طرفی از  $Y = V^T X$  داریم  $Y = V^T X$  یا

$$X = V(\Sigma^T \Sigma)^{-1} \Sigma^T U^T b \quad (15)$$

این جواب کمترین مربعات دستگاه  $AX = b$  است.

### ۷.۹ مثال

جواب کمترین مربعات مسأله‌ی داده شده را با استفاده از تجزیه SVD به دست آورید.

$$\begin{bmatrix} 1 & -2 \\ -2 & 4 \\ 2 & -1 \end{bmatrix} X = \begin{bmatrix} 0 \\ -1 \\ 2 \end{bmatrix}$$

حل: عامل‌های تجزیه SVD ماتریس ضرایب به صورت زیرند:

$$U = \begin{bmatrix} -0/4178 & 0/1596 & -0/8944 \\ 0/8355 & -0/3192 & -0/4472 \\ -0/3568 & -0/9342 & 0/0000 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 5/3307 & 0 \\ 0 & 1/2584 \\ 0 & 0 \end{bmatrix}$$

$$V = \begin{bmatrix} -0/5257 & -0/8507 \\ 0/8507 & -0/5257 \end{bmatrix}$$

اما

$$\Sigma^T \Sigma = \begin{bmatrix} 28/4164 & 0 \\ 0 & 1/5836 \end{bmatrix}, \quad (\Sigma^T \Sigma)^{-1} = \begin{bmatrix} 0/0352 & 0 \\ 0 & 0/6315 \end{bmatrix}$$

بعلاوه

$$\Sigma^T U^T b = \begin{bmatrix} -8/2583 \\ -1/9495 \end{bmatrix}$$

پس از (۱۵) داریم:

$$\begin{aligned} X &= V(\Sigma^T \Sigma)^{-1} \Sigma^T U^T b \\ &= \begin{bmatrix} -0/5257 & -0/8507 \\ 0/8507 & -0/5257 \end{bmatrix} \begin{bmatrix} 0/0352 & 0 \\ 0 & 0/6315 \end{bmatrix} \begin{bmatrix} -8/2583 \\ -1/9495 \end{bmatrix} \\ &= \begin{bmatrix} 1/2000 \\ 0/4000 \end{bmatrix} \end{aligned}$$

درواقع می‌توان دید که جواب دقیق مسأله  $X^* = \begin{bmatrix} 1/2 \\ 0/4 \end{bmatrix}$  است. بعلاوه

$$r = b - AX^* = \begin{bmatrix} \circ \\ -1 \\ 2 \end{bmatrix} - \begin{bmatrix} 1 & -2 \\ -2 & 4 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} 1/2 \\ \circ/4 \\ \circ/4 \end{bmatrix} = \begin{bmatrix} -\circ/4 \\ -\circ/2 \\ \circ \end{bmatrix} \neq 0.$$

$$\|r\|_2 = \left\| \begin{bmatrix} -\circ/4 \\ -\circ/2 \\ \circ \end{bmatrix} \right\|_2 = \circ/4472$$

پس دستگاه اصلی ناسازگار است زیرا در غیر این صورت می بایست مانده صفر شود.

### مثال ۷.۱۰

با محاسبه دقیق عامل های تجزیه SVD ماتریس ضرایب دستگاه داده شده نشان دهید که جواب دقیق کمترین مربعات دستگاه

$$\begin{cases} -2x_1 + 6x_2 = 3 \\ x_1 + 6x_2 = 1 \\ 2x_1 + 3x_2 = 4 \end{cases}$$

برابر است با

$$X = \left[ \frac{1}{3}, \frac{4}{9} \right]^T$$

حل: اگر عامل های تجزیه SVD ماتریس  $A$  را به صورت دقیق محاسبه کنیم داریم:

$$U = \begin{bmatrix} -\frac{2}{3} & -\frac{2}{3} & \frac{1}{3} \\ -\frac{1}{3} & \frac{1}{3} & -\frac{2}{3} \\ -\frac{1}{3} & \frac{1}{3} & \frac{2}{3} \end{bmatrix}, \quad V = \begin{bmatrix} \circ & 1 \\ -1 & \circ \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 9 & 0 \\ 0 & 3 \\ 0 & 0 \end{bmatrix}$$

اکنون طبق (۱۵) داریم:

$$X = V(\Sigma^T \Sigma)^{-1} \Sigma^T U^T b$$

اما

$$\Sigma^T \Sigma = \begin{bmatrix} 81 & 0 \\ 0 & 9 \end{bmatrix}; \quad (\Sigma^T \Sigma)^{-1} = \begin{bmatrix} \frac{1}{81} & 0 \\ 0 & \frac{1}{9} \end{bmatrix}$$

پس

$$X = \begin{bmatrix} \circ & 1 \\ -1 & \circ \end{bmatrix} \begin{bmatrix} \frac{1}{81} & 0 \\ 0 & \frac{1}{9} \end{bmatrix} \begin{bmatrix} 9 & 0 & 0 \\ 0 & 3 & 0 \end{bmatrix} \begin{bmatrix} -\frac{2}{3} & -\frac{2}{3} & -\frac{1}{3} \\ -\frac{2}{3} & \frac{1}{3} & \frac{2}{3} \\ \frac{1}{3} & -\frac{2}{3} & \frac{2}{3} \end{bmatrix} \begin{bmatrix} 3 \\ 1 \\ 4 \end{bmatrix} = \begin{bmatrix} \frac{1}{3} \\ \frac{4}{9} \end{bmatrix}$$

اکنون بردار باقی مانده را محاسبه کرده و در مورد سازگاری دستگاه بحث کنید.

۱۰.۳ خلاصه‌ای از حل دستگاه  $AX = b$  با استفاده از روش تجزیه SVD در حالتی که رتبه ماتریس ضرایب کامل است.

در ادامه خلاصه‌ای از حل دستگاه  $AX = b$  به روش SVD آورده شده است. در همهی حالات فرض شده است که  $A$  رتبه‌ی کامل باشد و  $A = U\Sigma V^T$  تجزیه مقادیر تکین است.

### ۱. حل دستگاه مربعی $AX = b$

$$X = V\Sigma^{-1}U^T b \quad (m = n)$$

### ۲. حل دستگاه غیرمربعی فرامعین $AX = b$ (جواب کمترین مربعات)

$$X = V(\Sigma^T \Sigma)^{-1} \Sigma^T U^T b \quad (m > n)$$

#### تمرین ۷.۱

##### جواب دستگاه مربعی

$$\begin{bmatrix} 1 & \frac{1}{2} & \frac{1}{3} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} \end{bmatrix} X = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$$

را با استفاده از تجزیه SVD به دست آورید.

#### تمرین ۷.۲

##### جواب کمترین مربعات دستگاه فرامعین

$$\begin{bmatrix} 2 & -1 & 3 \\ 7 & 0 & 1 \\ 6 & 1 & -2 \\ 2 & 1 & -3 \end{bmatrix} X = \begin{bmatrix} -1 \\ 2 \\ 3 \\ 4 \end{bmatrix}$$

را با استفاده از تجزیه SVD ماتریس ضرایب این دستگاه به دست آورید.

## ۴ رابطه بین مقادیر تکین یک ماتریس و دترمینان و عددحالت و بعضی نرم‌های ماتریسی آن ماتریس

در این قسمت با استفاده از تجزیه SVD روابط زیر را ثابت می‌کنیم:

۱. برای ماتریس مربعی  $A$  داریم

$$\|A\|_2 = \sigma_{\max} \quad , \quad \|A^{-1}\|_2 = \frac{1}{\sigma_{\min}} \quad (16)$$

جایی که  $\sigma_{\max}$  و  $\sigma_{\min}$  به ترتیب نشان دهنده‌ی کوچکترین و بزرگترین مقادیر تکین  $A$  است.

۲. برای ماتریس دلخواه مربعی یا غیرمربعی  $A$  داریم

$$\kappa_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}} \quad (17)$$

۳. برای نرم فروبنیوس ماتریس دلخواه  $A$  داریم

$$\|A\|_F = \sqrt{\sigma_1^2 + \sigma_2^2 + \cdots + \sigma_r^2} \quad (18)$$

جایی که  $r$  رتبه  $A$  است.

۴. اگر  $A$  ماتریسی مربعی متقارن باشد آنگاه  $|\lambda_i| = \sigma_i$  که مقادیر ویژه  $A$  اند.

۵. برای ماتریس مربعی  $A, n \times n$  داریم

$$|det(A)| = \prod_{i=1}^n \sigma_i$$

۶. رتبه ماتریس های دلخواه  $A$  و  $A^T A$  و  $AA^T$  برابرند.

اثبات ۱: با استفاده از تعریف و خواص نرم ۲ داریم:

$$\|A\|_2 = \|U\Sigma V^T\|_2 = \|\Sigma\|_2 = \left\| \begin{bmatrix} \sigma_1 & & & & & \circ & & \\ & \sigma_2 & & & & & & \\ & & \ddots & & & & & \\ & & & \sigma_r & & & & \\ & & & & \circ & & & \\ & & & & & \ddots & & \\ & & & & & & \circ & \\ \circ & & & & & & & \circ \end{bmatrix} \right\|_2 \\ = \max\{\sigma_1, \sigma_2, \dots, \sigma_r\} = \sigma_1 = \sigma_{\max}$$

توجه کنید که در اثبات رابطه  $\|A\|_2 = \sigma_{\max}$  از این حقیقت استفاده شده است که برای هر ماتریس قطری  $D = diag(d_1, \dots, d_n)$  داریم  $D = diag(d_1, \dots, d_n)$  (نشان دهید)

$$\|D\|_2 = \max\{|d_1|, \dots, |d_n|\}$$

استفاده شده است.  
به همین صورت می توان دید که:

$$\begin{aligned} \|A^{-1}\|_2 &= \left\| (U\Sigma V^T)^{-1} \right\|_2 = \left\| (V^T)^{-1} \Sigma^{-1} U^{-1} \right\|_2 \\ &= \left\| (V^{-1})^T \Sigma^{-1} U^{-1} \right\|_2 = \left\| (V^T)^T \Sigma^{-1} U^{-1} \right\|_2 \\ &= \left\| V \Sigma^{-1} U^T \right\|_2 = \left\| \Sigma^{-1} \right\|_2 = \left\| \begin{bmatrix} \sigma_1^{-1} & & & & & \circ & & \\ & \sigma_2^{-1} & & & & & & \\ & & \ddots & & & & & \\ & & & \sigma_r^{-1} & & & & \\ & & & & \circ & & & \\ & & & & & \ddots & & \\ & & & & & & \circ & \\ \circ & & & & & & & \circ \end{bmatrix} \right\|_2 \\ &= \max\{\sigma_1^{-1}, \sigma_2^{-1}, \dots, \sigma_r^{-1}\} \end{aligned}$$

و چون  $\sigma_1^{-1} \leq \sigma_2^{-1} \leq \dots \leq \sigma_r^{-1}$  پس لذا

$$\|A^{-1}\|_2 = \max\{\sigma_1^{-1}, \sigma_2^{-1}, \dots, \sigma_r^{-1}\} = \sigma_r^{-1} = \frac{1}{\sigma_r} = \frac{1}{\sigma_{\min}}$$

اثبات ۲: بر طبق تعریف عدد حالت در نرم ۲ داریم:

$$\kappa_2(A) = \|A\|_2 \|A^{-1}\|_2$$

اکنون با توجه به روابط قسمت ۱ به دست می آوریم:

$$\kappa_2(A) = \sigma_1 \times \frac{1}{\sigma_r} = \frac{\sigma_1}{\sigma_r} = \frac{\sigma_{\max}}{\sigma_{\min}}$$

توجه کنید که طبق این تساوی هر چه  $\sigma_{\max}$  نزدیک تر باشد ماتریس  $A$  خوش حالت تر خواهد بود.

اثبات ۳: تمرین

اثبات ۴: طبق تعریف  $\sigma_i$  ها می توانیم بنویسیم

$$\sigma_i = \sqrt{\lambda_i(A^T A)} = \sqrt{\lambda_i(A A)} = \sqrt{\lambda_i(A^2)} = \sqrt{(\lambda_i(A))^2} = |\lambda_i(A)| = |\lambda_i|$$

اثبات ۵: فرض کنید  $A = U \Sigma V^T$  تجزیه مقادیر تکین  $A$  باشد. از آنجایی که دترمینان ماتریس متعامد  $U$  و  $V$  یا یک است و یا منفی یک می توان دریافت که

$$|det(A)| = |det(U \Sigma V^T)| = |det(\Sigma)| = det \begin{bmatrix} \sigma_1 & & & \\ & \sigma_r & & \\ & & \ddots & \\ & & & \sigma_n \end{bmatrix} = \sigma_1 \sigma_2 \dots \sigma_n = \prod_{i=1}^n \sigma_i$$

و اثبات کامل می شود.

اثبات ۶: باید ثابت کنیم  $Rank(A^T A) = Rank(A)$ . با توجه به خواص رتبه که در فصل اول بررسی شد برای سه ماتریس  $A$  و  $B$  و  $C$  می توان نوشت:

$$Rank(B A C) = Rank(A)$$

به شرطی که  $B$  و  $C$  وارون پذیر باشند. به عبارتی اگر ماتریس های وارون پذیر از سمت چپ و راست در یک ماتریس ضرب شوند تاثیری در رتبه ای آن ندارند. از طرفی اگر  $A = U \Sigma V^T$  تجزیه مقدار تکین  $A$  باشد داریم:

$$\begin{aligned} A^T A &= (U \Sigma V^T)^T (U \Sigma V^T) = (V \Sigma^T U^T) (U \Sigma V^T) \\ &= V \Sigma^T (U^T U) \Sigma V^T = V \Sigma^T I \Sigma V^T \\ &= V \Sigma^T \Sigma V^T \end{aligned}$$

$$Rank(A^T A) = Rank(V \Sigma^T \Sigma V^T) = Rank(\Sigma^T \Sigma)$$

اکنون با توجه به اینکه  $\Sigma$  ماتریس  $n \times m$  و به صورت

$$\Sigma = \begin{bmatrix} \Sigma_1 & \circ \\ \circ & \circ \end{bmatrix}_{m \times n}, \quad \Sigma_1 = \begin{bmatrix} \sigma_1 & & & \circ \\ & \sigma_2 & & \\ & & \ddots & \\ \circ & & & \sigma_r \end{bmatrix}$$

است داریم:

$$\begin{aligned}\Sigma^T \Sigma &= \begin{bmatrix} \Sigma_1 & \circ \\ \circ & \circ \end{bmatrix}_{m \times n}^T \begin{bmatrix} \Sigma_1 & \circ \\ \circ & \circ \end{bmatrix}_{m \times n} = \begin{bmatrix} \Sigma_1 & \circ \\ \circ & \circ \end{bmatrix}_{n \times m} \begin{bmatrix} \Sigma_1 & \circ \\ \circ & \circ \end{bmatrix}_{m \times n} \\ &= \begin{bmatrix} \Sigma_1^T \Sigma_1 & \circ \\ \circ & \circ \end{bmatrix}_{n \times n} = \begin{bmatrix} \Sigma_1^2 & \circ \\ \circ & \circ \end{bmatrix}_{n \times n}\end{aligned}$$

پس واضح است که:

$$\text{Rank}(A^T A) = \text{Rank}(\Sigma^T \Sigma) = \text{Rank}(\Sigma_1^2) = \text{Rank}(\Sigma_1) = r \quad (19)$$

از طرفی:

$$\text{Rank}(A) = \text{Rank}(U \Sigma V^T) = \text{Rank}(\Sigma) = \text{Rank}(\Sigma_1) = r \quad (20)$$

از (19) و (20) داریم  $\text{Rank}(A^T A) = \text{Rank}(A)$  و اثبات کامل می شود. دقت کنید که با روندی کاملا مشابه می توان دریافت که رابطه زیر نیز برقرار است:

$$\text{Rank}(AA^T) = \text{Rank}(A)$$

## ۵ اثر یک ماتریس بر یک ناحیه یا یک شکل


فرض کنید  $X \in \mathbb{R}^n$  برداری دلخواه و  $A$  ماتریس  $m \times n$  باشد. حاصل  $A$  در  $X$  برداری چون  $Y$  است که  $Y = AX$ . یعنی ماتریس  $A$  هر برداری از  $\mathbb{R}^n$  را به برداری در  $\mathbb{R}^m$  می نگارد. لذا ماتریس  $A$ ،  $m \times n$  را می توانیم به عنوان یک تبدیل هندسی از  $\mathbb{R}^n$  به  $\mathbb{R}^m$  درنظر بگیریم. برای روشن شدن موضوع فرض کنید  $A$  ماتریس  $2 \times 2$  به صورت زیر است:

$$A = \begin{bmatrix} 1 & -3 \\ -1 & 2 \end{bmatrix}$$

به علاوه بردار (نقطه)  $X = \begin{bmatrix} 2 \\ 1 \end{bmatrix} \in \mathbb{R}^2$  را در نظر می گیریم. داریم:


$$Y = AX = \begin{bmatrix} 1 & -3 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

بنابراین  $A$  بردار (نقطه)  $\begin{bmatrix} -1 \\ 0 \end{bmatrix}$  را به شکل زیر توجه کنید (می نگارد)



تا به اینجای کار دیدیم که هر ماتریس  $m \times n$  به عنوان یک تبدیل هندسی قادر به نگاشتن نقطه‌ای دلخواه از  $\mathbb{R}^n$  به نقطه‌ای از  $\mathbb{R}^m$  است. حال سوالی که مطرح می‌گردد: اگر  $\Gamma$  یک شکل هندسی خاص در  $\mathbb{R}^n$  باشد آنگاه تحت تاثیر  $A$  بر این شکل می‌باشد منظر چه شکلی در  $\mathbb{R}^m$  باشیم؟ در این حالت خاص فرض کنید که  $A$  همان ماتریس  $2 \times 2$  قبلی باشد و  $\Gamma$  مجموعه‌ی دایره‌ی یکه‌ی توپر در  $\mathbb{R}^2$  باشد یعنی:

$$\Gamma = \{X = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \in \mathbb{R}^2 \mid \|X\|_2 \leq 1\} = \{X = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \in \mathbb{R}^2 \mid x_1^2 + x_2^2 \leq 1\}$$



می‌خواهیم بررسی نمایم که  $A$  شکل  $\Gamma$  را به چه شکلی در  $\mathbb{R}^2$  می‌نگارد. برای اینکار باید  $A$  بر تمامی نقاط  $\Gamma$  اثر نماید تا شکل جدید حاصل گردد. فرض کنیم  $X$  نقطه‌ای دلخواه از  $\Gamma$  باشد پس:

$$X = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \in \Gamma \Rightarrow x_1^2 + x_2^2 \leq 1 \quad (21)$$

می‌خواهیم اثر  $A$  بر این نقطه‌ی دلخواه را بیابیم. اگر  $Y = AX$  یا

$$X = A^{-1}Y \Rightarrow \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = A^{-1}Y = \begin{bmatrix} 1 & -3 \\ -1 & 2 \end{bmatrix}^{-1} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} -2 & -3 \\ -1 & -1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} -2y_1 - 3y_2 \\ -y_1 - y_2 \end{bmatrix}$$

پس

$$\begin{cases} x_1 = -2y_1 - 3y_2 \\ x_2 = -y_1 - y_2 \end{cases}$$

با توجه به اینکه  $x_1$  و  $x_2$  می‌باشد در (21) صدق کنند باید داشته باشیم

$$x_1^2 + x_2^2 \leq 1 \Rightarrow (-2y_1 - 3y_2)^2 + (-y_1 - y_2)^2 \leq 1$$


یا

$$5y_1^2 + 14y_1y_2 + 10y_2^2 \leq 1$$

اکنون با استفاده از نرم افزاری‌های ریاضی به رسم ناحیه‌ی جدید

$$\begin{aligned} \Gamma' &= \{Y \in \mathbb{R}^2 \mid \|X\|_2 \leq 1\} \\ &= \left\{ \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} \in \mathbb{R}^2 \mid x_1^2 + x_2^2 \leq 1 \right\} \\ &= \left\{ \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} \in \mathbb{R}^2 \mid 5y_1^2 + 14y_1y_2 + 10y_2^2 \leq 1 \right\} \end{aligned}$$

می پردازیم که به صورت زیر است. مشاهده می شود که شکل جدید یک بیضی است که دوران یافته است زیرا یک بیضی افقی یا قائم نیست.



بنابراین ماتریس  $A$  در این مثال یک دایره را به یک بیضی دوران یافته تبدیل می کند.


### ۱.۰۵ اثر یک ماتریس متعامد بر یک شکل

حال فرض کنید  $A$  ماتریس متعامد باشد یعنی  $A^T A = I$  و  $\Gamma$  همان شکل قبل باشد اگر  $Y \in \Gamma$  باشد آنگاه از  $Y = AX$  و  $\|X\|_2 \leq 1$  داریم:


$$Y = AX \rightarrow A^T Y = A^T A X = IX = X$$

لذا  $X = A^T Y$  داریم:  $\|X\|_2 = \|A^T Y\|_2 = \|Y\|_2$

پس  $\|X\|_2 \leq 1$  معادل است با  $\|Y\|_2 \leq 1$  یا  $\|Y\|_2 \leq 1$  که یک دایره توپر یکه در  $\mathbb{R}^2$  است لذا  $\Gamma'$  یک دایره توپر خواهد بود



اما در حالت کلی دایره  $\Gamma'$  همان دایره  $\Gamma$  نیست و ممکن است دوران نیز یافته باشد پس برای دقیق تر نمایش دادن تاثیر  $A$  بر  $\Gamma$  از شکل زیر استفاده می کنیم.



تا دوران احتمالی دایره‌ی سمت چپ را نشان داده باشیم. به طور کلی نتیجه‌ی زیر را به دست آورده‌یم:

اگر ماتریس متعامد  $A$  بر یک دایره اثر کند شکل آن را تغییر نمی‌دهد تنها آن را دوران می‌دهد. اما اگر  $A$  ماتریس متعامد نباشد و بر یک دایره اثر کند هم شکل آن را به بیضی تغییر می‌دهد و هم آنرا دوران می‌دهد.

## ۲.۵ اثر یک ماتریس قطری بر شکل دایره

ماتریس قطری وارون پذیر  $A$  را به صورت زیر در نظر بگیرید

$$A = \begin{bmatrix} d_1 & 0 \\ 0 & d_2 \end{bmatrix}$$

اگر  $A$  بر دایره  $\Gamma$  اثر کند آنگاه برای هر  $Y \in \Gamma'$  داریم:

$$Y = AX \Rightarrow Y = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} d_1 & 0 \\ 0 & d_2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$


پس

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} d_1 & 0 \\ 0 & d_2 \end{bmatrix}^{-1} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} \frac{1}{d_1} & 0 \\ 0 & \frac{1}{d_2} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} \frac{y_1}{d_1} \\ \frac{y_2}{d_2} \end{bmatrix} \Rightarrow \begin{cases} x_1 = \frac{y_1}{d_1} \\ x_2 = \frac{y_2}{d_2} \end{cases}$$

لذا شرط  $1 \leq \|X\|_2$  نتیجه می‌دهد

$$x_1^2 + x_2^2 \leq 1 \Rightarrow \frac{y_1^2}{d_1^2} + \frac{y_2^2}{d_2^2} \leq 1$$


که نشان دهنده یک بیضی است (بدون دوران). بنابراین  $\Gamma'$  چیزی نیست بجز یک بیضی




البته بر حسب اینکه  $d_1$  از  $d_2$  بزرگ‌تر یا کوچک‌تر باشد بیضی قائم یا افقی خواهد بود.  
البته توجه کنید که اگر  $d_1 = d_2$  آنگاه داریم:

$$\frac{y_1^2}{d_1^2} + \frac{y_2^2}{d_1^2} \leq 1 \Rightarrow y_1^2 + y_2^2 \leq d_1^2$$


که نشان دهنده‌ی دایره به مرکز مبدا و شعاع  $d_1$  است. حال اگر  $1 > d_1$  آنگاه'  $\Gamma'$  دایره‌ای است که نسبت به  $\Gamma$  بزرگ‌تر است و اگر  $1 < d_1$  آنگاه'  $\Gamma'$  دایره است که نسبت به  $\Gamma$  کوچک‌تر است.  
حالت ۱ :  $d_1 > 1$



حالت ۱ :  $d_1 < 1$



بعلاوه اگر  $d_1 = d_2 = 1$  آنگاه  $A$  ماتریس همانی است و بر شکل  $\Gamma$  بی اثر خواهد بود.



با توجه به نکات گفته شده می توانیم بیان کنیم که:

اگر  $A$  ماتریسی قطری وارون پذیر دلخواه باشد آنگاه اثرش بر دایره یک دایره یا بیضی است که در مختصات جدید دوران نمی یابد

### تمرین ۷.۳

مانند مباحث قبل موارد زیر را بررسی کنید:

۱. اثر یک ماتریس متعامد بر یک بیضی، یک بیضی و با دوران است.
۲. اثر یک ماتریس قطری بر یک بیضی، یک بیضی و بدون دوران است.

## تمرین ۷.۴

ناحیه زیر را در نظر بگیرید:

$$\Gamma = \left\{ \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \in \mathbb{R}^2 \mid \frac{x_1^2}{4} + \frac{x_2^2}{9} \leq 1 \right\}$$

اثر ماتریس های  $A$ ،  $B$ ،  $C$  و  $D$  را بر ناحیه  $\Gamma$  به دست آورید.

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \quad B = \begin{bmatrix} -1 & 0 \\ 0 & 2 \end{bmatrix}, \quad C = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}, \quad D = \begin{bmatrix} \frac{4}{5} & -\frac{3}{5} \\ \frac{3}{5} & \frac{4}{5} \end{bmatrix}$$

## ۳.۵ تعبیر هندسی تجزیه SVD

با توجه به اینکه مقدمات لازم جهت تعبیر هندسی تجزیه SVD آورده شد اکنون به تعبیر آن می پردازیم. قبله دیدیم که ناحیه جدید  $\Gamma'$  به صورت زیر است

$$\Gamma' = \left\{ Y = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} \in \mathbb{R}^2 \mid \|Y\|_2 \leq 1 \right\}$$

و تجزیه SVD ماتریس  $A = U\Sigma V^T$  باشد داریم:

$$\Gamma' = \{Y \mid \|Y\|_2 \leq 1\} = \{AX \mid \|X\|_2 \leq 1\} = \{U\Sigma V^T X \mid \|X\|_2 \leq 1\}$$


این نگاشت را می توان به ۳ مرحله‌ی زیر تقسیم نمود.

مرحله‌ی ۱: ضرب  $X$  در  $V^T$


مرحله‌ی ۲: ضرب  $\Sigma$  در  $V^T X$

مرحله‌ی ۳: ضرب  $U$  در  $\Sigma V^T X$


مطابق مطالب بیان شده در مرحله‌ی اول و در ضرب  $V^T X$  متعامد است پس دایره به یک دایره با دوران تبدیل می شود یعنی شکل زیر:




در مرحله دوم در ضرب  $(V^T X)$  یعنی  $\tilde{Y} = \Sigma \tilde{X}$  چون  $\Sigma$  قطری است پس دایره به یک بیضی بدون دوران تبدیل می شود یعنی شکل زیر



در مرحله سوم در ضرب  $U\tilde{Y}$  چون  $U$  متعامد است بیضی به یک بیضی دوران یافته تبدیل می شود یعنی  
شکل زیر



این سه مرحله را می توان به صورت زیر نمایش داد



## ۶ کاربردهای تجزیه SVD

تجزیه SVD در علوم مختلف کاربردهای فراوان دارد از جمله پردازش سیگنال (Signal Processing)، داده کاوی (Data Mining)، پردازش تصویر (Image Processing)، الگوریتم های تشخیص چهره و غیره. در این درس به یکی از کاربردهای SVD در پردازش تصویر که فشرده سازی تصویر (Image Compressing) است می پردازیم. قبل از آن با فرم فشرده این تجزیه آشنا می شویم. دیدیم که شمای کلی تجزیه SVD به صورت زیر است:

$$A = \begin{matrix} m \\ \boxed{U} \\ m \end{matrix} \begin{matrix} m \\ \Sigma \\ n \end{matrix} \begin{matrix} n \\ \boxed{V^T} \\ n \end{matrix}$$

$$= \begin{matrix} m \\ \boxed{U} \\ m \end{matrix} \begin{matrix} r \\ \boxed{\Sigma_1} \\ r \end{matrix} \begin{matrix} n \\ \boxed{V^T} \\ n \end{matrix}$$

در ماتریس  $\Sigma$  بجز بلوک  $\Sigma_1$  بقیه بلوک ها صفرند پس وقتی  $\Sigma$  از چپ در  $V^T$  و از راست در  $U$  ضرب می شود تنها به  $r$  سطر و ستون آن که همان  $\Sigma_1$  است نیاز داریم یعنی (قسمت هایی که تاثیر ندارند هاشور زده شده اند)

$$= \begin{matrix} m \\ \boxed{U_r} \quad \boxed{\Sigma_1} \quad r \\ r \end{matrix} \begin{matrix} r \\ \boxed{\Sigma_1} \quad \boxed{V_r^T} \\ r \end{matrix} \begin{matrix} n \\ \boxed{V_r^T} \\ n \end{matrix}$$

پس  $A$  از ضرب ۳ ماتریس  $U_r, \Sigma_1, V_r^T$  به صورت زیر بدست می آید

$$A = U_r \Sigma_1 V_r^T \quad (22)$$

که به شکل زیر است

$$= \begin{matrix} m \\ \boxed{U_r} \\ r \end{matrix} \begin{matrix} r \\ \boxed{\Sigma_1} \\ r \end{matrix} \begin{matrix} r \\ \boxed{V_r^T} \\ n \end{matrix}$$

به (۲۲) شکل فشرده تجزیه SVD گفته می شود زیرا ماتریس های  $U_r, \Sigma_1, V_r^T$  نسبت به ماتریس های اولیه شان یعنی  $U, V, \Sigma$  از نظر ابعاد فشرده تر شده اند (از ابعاد کوچک تری برخوردارند)

حال با توجه به (۲۲) داریم

$$A = U_r \Sigma_1 V_r^T = [u_1, u_2, \dots, u_r] \begin{bmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \end{bmatrix} \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_r^T \end{bmatrix} = [\sigma_1 u_1, \sigma_2 u_2, \dots, \sigma_r u_r] \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_r^T \end{bmatrix}$$

$$= \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \dots + \sigma_r u_r v_r^T$$


### بنابراین

$$A = \sigma_1 u_1 v_1^T + \cdots + \sigma_r u_r v_r^T = \sum_{i=1}^r \sigma_i u_i v_i^T \quad (۲۳)$$

به (۲۳) شکل گسترده تجزیه SVD گفته می شود. برای یک ماتریس  $4 \times 4$  شکل گسترده به صورت زیر نمادین نمایش داده شده است. با توجه به اینکه  $\sigma_i$  ها نزولی هستند

$$\sigma_1 \geq \sigma_2 \geq \sigma_3 \geq \sigma_4$$

می توانیم  $\sigma_1$  را بزرگترین و  $\sigma_4$  را کوچکترین مقدار منفرد تلقی کنیم.



### نکته ۷.۳

با توجه به (۲۳) ماتریس  $A$  را می توان به صورت جمع  $r$  ماتریس به شکل  $\sigma_i u_i v_i^T$  نوشت. بعلاوه هر ماتریس به صورت  $\sigma_i u_i v_i^T$  دارای رتبه یک است. برای دیدن این موضوع برای حالت خاص  $n=2, m=3$  واضح است که  $u_i$  ها برداری  $1 \times 2$  و  $v_i$  ها برداری  $3 \times 1$  اند پس برای  $i$  ثابت می توان فرض کرد

$$u_i = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix}, \quad v_i = \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix}$$

پس داریم

$$u_i v_i^T = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix} \begin{bmatrix} \beta_1 & \beta_2 \end{bmatrix} = \begin{bmatrix} \alpha_1 \beta_1 & \alpha_1 \beta_2 \\ \alpha_2 \beta_1 & \alpha_2 \beta_2 \\ \alpha_3 \beta_1 & \alpha_3 \beta_2 \end{bmatrix} = \begin{bmatrix} \beta_1 & \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix} & \beta_2 & \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix} \end{bmatrix} = [\beta_1 u_i \quad \beta_2 u_i]$$

این نشان می دهد که در ماتریس  $u_i v_i^T$  ستون اول مضربی از ستون دوم است پس این ماتریس باید دارای رتبه یک باشد. به همین صورت در حالت کلی می توان نشان داد که هر ماتریس به صورت  $u_i v_i^T$  و به دنبال آن  $\sigma_i u_i v_i^T$  از رتبه یک است. بنابراین در (۲۳) هر  $r$  ماتریس از رتبه ۱ هستند بنابراین ماتریس  $A$  را به صورت مجموع  $r$  ماتریس رتبه یک نوشتهیم.

## ۱۰.۶ بهترین تقریب رتبه پایین یک ماتریس

با توجه به (۲۳) اگر  $k$  جمله را جدا کنیم ( $k \leq r$ ) آنگاه

$$A_k = \sigma_1 u_1 v_1^T + \cdots + \sigma_k u_k v_k^T = \sum_{i=1}^k \sigma_i u_i v_i^T$$

توجه کنید که رتبه  $A_k$  برابر  $k$  خواهد بود. چرا؟  
حال یک سوال مطرح می شود. در بین تمام ماتریس های از رتبه  $k$  نزدیک ترین آنها به  $A$  کدام است؟ جواب در قضیه زیر آمده است

### قضیه ۷.۳ اکارت- یانگ- میرسکی (Eckart- Young- Mirsky)

در بین تمام ماتریس های از رتبه  $k$  ماتریس  $A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$  بهترین تقریب  $A$  است. یعنی برای هر ماتریس دیگر  $X$  داریم

$$\|A - A_k\|_2 \leq \|A - X\|_2$$

علاوه دقت این تقریب برابر است با:

$$\|A - A_k\|_2 = \sigma_{k+1}$$

ممکن است پرسیده شود که چه نیازی است تا ماتریس  $A$  با رتبه  $r$  را با یک ماتریس رتبه  $k \leq r$  تقریب بزنیم. پاسخ در تعریف رتبه عددی یک ماتریس است. قبل از آن ماتریس  $A$  را به صورت زیر در نظر بگیرید.

$$A = \begin{bmatrix} ۰/۶۰ & -۰/۴۷ & ۰/۵۶ \\ -۰/۱۴ & -۰/۷۱ & -۰/۱۳ \\ ۰/۸۲ & -۰/۷۳ & ۰/۷۹ \\ -۰/۶۴ & ۰/۷۴ & -۰/۶۷ \end{bmatrix}$$

چون ستون های  $A$  مستقل خطی اند می توان دید که  $A$  رتبه کامل است پس  $Rank(A) = ۳$ . با کمی دقت در ماتریس  $A$  می بینیم که ستون اول نزدیک به ستون سوم است (اگرچه یکی نیستند) بنابراین می توانیم رتبه  $A$  را به صورت تقریبی ۲ در نظر بگیریم. این کار منطقی است زیرا از ۳ مقدار تکین  $A$  که به صورت

$$\sigma_1 = ۲/۰۴, \quad \sigma_2 = ۰/۷۰, \quad \sigma_3 = ۰/۰۴$$

هستند کوچکترین آنها مقداری کوچک است و می توان از آن صرف نظر نمود (دقت کنید که رتبه ماتریس برابر با تعداد مقادیر تکین ناصفراست). پس اگر به این ماتریس به اینصورت بنگریم در اینصورت می توانیم بنویسیم  $Rank(A) \approx ۲$ . در این مثال می گوییم رتبه ماتریس  $A$  برابر ۳ است اما رتبه عددی آن ۲ است. حال که رتبه عددی ماتریس ۲ است پس می توانیم  $A$  را با یک ماتریس رتبه پایین تر از رتبه اصلی اش که ۳ است تقریب نماییم.  
اکنون با توجه به قضیه قبل می توان ماتریس  $A$  را به صورت زیر تقریب زد.

$$A \approx A_2 = U_2 \Sigma_2 V_2^T = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T \quad (k = ۲)$$

زیرا بهترین تقریب رتبه ۲ همان  $A_2$  است. با توجه به اینکه برای این ماتریس عامل های تجزیه SVD به صورت زیرند (محاسبه

کنید):

$$U = \begin{bmatrix} -\frac{1}{46} & \frac{1}{16} & -\frac{1}{54} & \frac{1}{69} \\ -\frac{1}{13} & -\frac{1}{98} & -\frac{1}{17} & \frac{1}{1} \\ -\frac{1}{66} & \frac{1}{13} & -\frac{1}{28} & -\frac{1}{69} \\ \frac{1}{58} & \frac{1}{6} & -\frac{1}{78} & -\frac{1}{23} \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \frac{1}{4} & & & \\ & \frac{1}{70} & & \\ & & \frac{1}{4} & \\ & & & \frac{1}{4} \end{bmatrix}$$

$$V = \begin{bmatrix} -\frac{1}{57} & \frac{1}{44} & -\frac{1}{69} \\ \frac{1}{60} & \frac{1}{80} & \frac{1}{1} \\ -\frac{1}{56} & \frac{1}{41} & \frac{1}{72} \end{bmatrix}$$

پس داریم

$$A_2 = \frac{1}{4} \begin{bmatrix} -\frac{1}{46} \\ -\frac{1}{13} \\ -\frac{1}{66} \\ \frac{1}{58} \end{bmatrix} \begin{bmatrix} -\frac{1}{57} \\ \frac{1}{60} \\ -\frac{1}{56} \end{bmatrix}^T + \frac{1}{70} \begin{bmatrix} \frac{1}{16} \\ -\frac{1}{98} \\ \frac{1}{13} \\ \frac{1}{6} \end{bmatrix} \begin{bmatrix} \frac{1}{44} \\ \frac{1}{80} \\ \frac{1}{41} \end{bmatrix}^T$$

$$= \begin{bmatrix} \frac{1}{59} & -\frac{1}{47} & \frac{1}{57} \\ -\frac{1}{14} & -\frac{1}{71} & -\frac{1}{13} \\ \frac{1}{81} & -\frac{1}{73} & \frac{1}{80} \\ -\frac{1}{66} & \frac{1}{74} & -\frac{1}{65} \end{bmatrix}$$

همچنین خطای تقریب نسبت به نرم ۲ برابر است با

$$\|A - A_2\|_2 = \left\| \begin{bmatrix} \frac{1}{1} & \frac{1}{00} & -\frac{1}{01} \\ \frac{1}{00} & \frac{1}{00} & \frac{1}{00} \\ \frac{1}{01} & \frac{1}{00} & -\frac{1}{01} \\ \frac{1}{02} & \frac{1}{00} & -\frac{1}{02} \end{bmatrix} \right\|_2 = \frac{1}{4} = \sigma_2$$

که مقداری کوچک است.

اکنون ممکن است بپرسید که انجام عملیات های مختلف با  $A_k$  چه مزایایی نسبت به  $A$  دارد؟ دلیل اینکار نیاز به حافظه کمتر برای ذخیره سازی  $A_k$  نسبت به  $A$  است.

اگر با خود ماتریس  $A$  کارکنیم به  $m \times n$  درایه برای ذخیره سازی نیازمندیم اما اگر با فرم فشرده آن به صورت  $A_k = U_k \Sigma_k V_k^T$  کار کنیم کافی است ماتریس های  $U_k, \Sigma_k, V_k$  را ذخیره کنیم پس با این سه ماتریس هر عملیاتی که لازم باشد می توان انجام داد. از طرفی:

• برای ذخیره سازی  $U_k$  به  $m \times k$  درایه نیازمندیم

• برای ذخیره سازی  $\Sigma_k$  چون قطری است به  $k$  درایه نیازمندیم

• برای ذخیره سازی  $V_k$  به  $n \times k$  درایه نیازمندیم

پس در مجموع برای ذخیره سازی  $A_k$  به

$$m \times k + k \times k + k \times n = k(m + n + 1)$$

دراایه نیازمندیم. پس برای ذخیره سازی ماتریس  $A$  به  $mn$  مکان حافظه نیازمندیم در حالی که برای ذخیره سازی ماتریس  $A_k$  به  $k(m + n + 1)$  مکان حافظه نیازمندیم. واضح است که هدف اصلی این است که

$$k(m + n + 1) < mn$$

پس مقدار  $k$  باید در شرط

$$k < \frac{mn}{m+n+1}$$

صدق نماید. توجه کنید که در حالت کلی هیچ مقدار بهینه ای برای  $k$  تعیین نشده است.

برای مثال فرض کنید  $A$  ماتریس  $1000 \times 50$  باشد. در این صورت برای ذخیره سازی  $A$  نیاز به ذخیره سازی  $50000$  درایه نیازمندیم. اما اگر رتبه عددی آن  $10 = k$  باشد آنگاه به ذخیره سازی

$$k(m+n+1) = 10(50 + 1000 + 1) \approx 10000$$

درایه نیازمندیم که نسبت به  $50000$  مقداری کوچک است. پس از نسبت

$$\frac{10000}{50000} = 20\%$$


می توان گفت که  $80$  درصد موفق به ذخیره سازی حافظه شده ایم. چون

$$k < \frac{mn}{m+n+1} = \frac{50000}{1051} \approx 47/57$$


پس در اینجا حداقل مقدار قابل قبول برای  $k$  برابر  $47$  است.

## ۷ تصویر به صورت یک ماتریس

هر عکس شامل یک عرض و طول است که مرز عکس را مشخص می کند و هر نقطه آن مقداری می پذیرد. به عبارت دیگر اگر تصویر را یک تابع پیوسته  $f(x, y)$  در نظر بگیریم در عرض  $x$  و در طول  $y$  مقدار مشخص تابع برابر با  $f(x, y)$  است که نشانگر مقدار رنگ آن در نقطه می باشد.




چون ضابطه ای برای تابع  $f(x, y)$  نداریم پس اگر بخواهیم تصویر را ذخیره کنیم باید تمام نقاط آن را ذخیره کنیم، اما در عمل برای ذخیره سازی ناچاریم تعداد متناهی از نقاط را در نظر گرفته و ذخیره نماییم. در نتیجه تنها یک نماینده از عکس واقعی خواهیم داشت که در پردازش تصویر به این کار نمونه گیری می گویند. از طرفی هر نقطه می تواند عددی را به عنوان رنگ به خود اختصاص دهد و چون بینهایت مقدار برای رنگ وجود دارد به ناچار باید یک مقدار را بعنوان رنگ هر نقطه بپذیریم که به این عمل کمی سازی گفته می شود. در شکل زیر لبه های تصویر با کمک مربع هایی مشخص شده اند، به این عمل دیجیتال کردن گفته می شود.




در واقع نتیجه حاصل از کمی سازی روی نماینده تصویر تولید یک ماتریس از مقادیر حقیقی است. یک تصویر دیجیتال، از طریق ماتریس به شکل زیر قابل نمایش است.

$$\begin{bmatrix} f(1,1) & f(1,2) & \dots & f(1,n) \\ f(2,1) & f(2,2) & \dots & f(2,n) \\ \vdots & \vdots & & \vdots \\ f(m,1) & f(m,2) & \dots & f(m,n) \end{bmatrix}$$

به هر کدام از عناصر (درایه) این ماتریس پیکسل گفته می شود. این عناصر می توانند مقداری بین  $0^{\circ}$  و  $255^{\circ}$  دریافت کنند. برای رنگ سیاه و  $255^{\circ}$  برای رنگ سفید. شکل های زیر نشان دهنده ای نسبت دادن مقدار به هر رنگ پیکسل ها را نشان می دهند.




$$= \begin{bmatrix} 255 & 0 & 255 \\ 0 & 128 & 0 \\ 128 & 0 & 255 \end{bmatrix}$$



$$= \begin{bmatrix} 0 & 150 & 180 & 255 & 80 \\ 255 & 120 & 255 & 180 & 255 \\ 100 & 200 & 30 & 255 & 0 \end{bmatrix}$$

توجه نمایید که می توانیم به هر رنگ مقداری در بازه  $[0^{\circ}, 255^{\circ}]$  نیز نسب دهیم در واقع با انتقال بازه  $[1^{\circ}, 255^{\circ}]$  به  $[0^{\circ}, 1^{\circ}]$  اینکار انجام می شود.

شکل زیر نیز بخوبی نشان می دهد که هر تصویر از پیکسل های بسیار ریزی تشکیل شده است و اینکه رنگ هر پیکسل مقداری بین  $0^{\circ}$  تا  $255^{\circ}$  را می گیرد. توجه کنید که در قسمتی از تصویر زوم شده است.




## ۱.۷ تبدیل تصاویر به ماتریس در نرم افزار متلب


در ادامه نحوه خواندن یک تصویر در محیط ویندوز و با استفاده از نرم افزار متلب آورده شده است. عکس دوربین زیر را در نظر بگیرید:




این عکس را که با فرمت jpg است به نام camera در پوشه‌ای به نام Desktop ذخیره می‌کنیم (به کادر قرمز رنگ زیر که از محیط نرم افزار متلب گرفته شده است دقت کنید)



سپس با دستور `imread` آن را در نرم افزار متلب فراخوانی می‌کنیم:




به سمت راست تصویر بالا دقت کنید. مطلب عکس یاد شده را به صورت یک ماتریس ۳ لایه ذخیره کرده است. همچنین ابعاد هر یک از ماتریس‌ها  $300 \times 300$  می‌باشند. که هر ماتریس یا لایه یکی از رنگ‌های قرمز، سبز و آبی را ذخیره می‌کند.



توجه کنید که تمام رنگ‌های موجود به کمک ترکیبی از این ۳ رنگ آبی، سبز و قرمز ساخته می‌شوند بعلاوه پیکسل هر لایه می‌تواند مقداری بین ۰ تا ۲۵۵ باشد. همچنین توجه کنید که اگر تصویری خاکستری باشد (که در واقع دیگر رنگی نیست) آنگاه ماتریس‌های سه لایه دقیقاً یکی هستند. البته در این مثال چون تصویر خاکستری است ماتریس‌های هر سه لایه در واقع یکی هستند.


حال با دستور `imtool(A)` تصویر را نمایش می‌دهیم. نتیجه چنین است:




حال می توانیم به مشاهدهای پیکسل های این تصویر با استفاده از کلیک روی گزینه های

Tools → Pixel Region


پردازیم. نتیجه چنین است:





مستطیل داخل کادر زرد رنگ بزرگنمایی قسمتی از تصویر که در کادر آبی رنگ قرار دارد می باشد. همان طور که می بینید در اینهای تمامی پیکسل ها از صفر تشکیل شده اند یعنی رنگ سیاه و این به علت آن است که کادر آبی رنگ قسمتی از تصویر که تیره است را نشانه گرفته است. با جابجایی کادر آبی رنگ با استفاده از ماوس آن را به قسمت روشن تر تصویر انتقال داده و مشاهده می کنیم که اعداد نشان داده شده در کادر زرد رنگ مقادیر بزرگتر را اختیار می کنند.




در ادامه مرحله به مرحله بر روی تصویر زوم کرده‌ایم تا جایی که پیکسل‌ها مشاهده شوند.




با زوم بیشتر داریم







با زوم بیشتر داریم



با زوم بیشتر داریم




با زوم بیشتر داریم



در تصویر بالا پیکسل های تصویر اصلی قابل مشاهده هستند. مشاهده می شود که هر پیکسل از مقدار خاصی برخوردار است.

همان‌طور که گفتیم برای تصاویر خاکستری هر سه ماتریس برای لایه‌های (لایه‌های) قرمز، سبز و آبی یکسان هستند (مگر اینکه اختلاف بسیار جزئی داشته باشند).

بنابراین می‌توانیم پردازش‌های مربوط به عکس را تنها با یکی از ماتریس‌ها انجام دهیم (اگر چه برای تصاویر رنگی هر سه ماتریس متفاوت هستند و پردازش برای هر یک از آن‌ها به طور جداگانه باید انجام شود). با استفاده از دستورات زیر ماتریس هر سه لایه را از ماتریس سه لایه‌ی اصلی جدا کنیم.




```

>> A = imread('camera.jpg');
>> imtool(A)
>> A1 = A(:, :, 1);
>> A2 = A(:, :, 2);
>> A3 = A(:, :, 3);
fx >> |

```

همان‌طور که در کادر زرد رنگ سمت راست شکل فوق می‌بینید ماتریس‌های  $A_1, A_2, A_3$  در واقع ماتریس‌هایی با ابعاد  $300 \times 300$  می‌باشند.

البته قبل از اینکه با آن‌ها عملیات ماتریسی انجام دهیم باید با استفاده از دستورات زیر آن‌ها را به ماتریسی که برای نرم افزار متلب قابل خواندن باشد تبدیل کنیم:



```

>> A1 = double(A1);
>> A2 = double(A2);
>> A3 = double(A3);
>> |

```


باز هم تاکید می‌کنیم که در اینجا ماتریس‌های  $A_1, A_2, A_3$  یکی هستند، چون تصویر خاکستری است و در این موارد هر پیکسل تصویر تنها از یک عدد تشکیل می‌شود.  
 اکنون با استفاده از دستور زیر متوجه می‌شویم که رتبه ماتریس  $A_1$  برابر  $300$  است.

>> rank(A1)

ans =

300

همچنین با رسم مقادیر تکین این ماتریس با شکل زیر مواجه خواهیم شد. مطابق این شکل به طور تقریبی می‌توان گفت که تنها  $100$  مقدار تکین بزرگ‌تر ماتریس  $A$  بزرگ هستند و مقادیر تکین بعدی مقداری ناچیز خواهند بود پس می‌توانیم رتبه عددی این ماتریس را  $100$  فرض کنیم.



## ۸ فشرده‌سازی تصویر


در فشرده‌سازی تصویر ابتدا تصویر به سه ماتریس (یا سه لایه) تبدیل می‌شود و با فرض اینکه رتبه این ماتریس‌ها  $r$  باشد آنگاه برای هر ماتریس تقریب رتبه  $r \leq k$  به شکل

$$A_k = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \cdots + \sigma_k u_k v_k^T$$

به دست می‌آید. در نهایت با این سه ماتریس تقریبی که نسبت به ماتریس‌های اصلی نیاز به حافظه‌ی کمتری نیز دارند تصویر تقریبی تشکیل می‌شود. توجه کنید که ابتدا قبیل از فشرده‌سازی تصویر با استفاده از دستور `im2double` اعداد تصویر را مقیاس نموده و به بازه‌ی  $[0, 1]$  انتقال می‌دهیم. در زیر کد ساده‌ای در نرم افزار متلب جهت فرآیند فشرده‌سازی تصویر آورده است (این کد برای تصاویر رنگی و خاکستری قابل استفاده است).


```
clc
clear all
close all
B=imread('camera.jpg');
I=im2double(B);
k=1;
for i = 1:3
    [U,S,V] = svd(I(:,:,i));
    A(:,:,i) = U(:,1:k)*S(1:k,1:k)*V(:,1:k)';
end
A(A>1)=1; A(A<0)=0;
imshow(A)
```


با اجرای این برنامه برای چند مقدار مختلف از  $k$  به رسم تصویر فشرده شده می‌پردازیم. با توجه به نتایج به دست آمده تصویر به ازای  $k = 50$  از دقت خوبی برخوردار است بعلاوه برای  $k = 100$  تصویری آنچنان شبیه تصویر اصلی است که اختلافی بین آن‌ها با چشم دیده نمی‌شود! اگرچه از لحاظ جنبه‌ی ریاضی ماتریس‌های مربوط به دو تصویر اصلی و فشرده شده با  $k = 100$  اساسا با هم برابر نمی‌باشند. این بخاطر آن است که تقریب‌های رتبه  $100$  برای سه ماتریس در تصویر به ازای  $k = 100$  در واقع تقریب‌های رتبه پایین خوب و دقیقی از ماتریس‌های اصلی مربوط به تصویر اصلی هستند.



$$\begin{aligned} \text{حجم اولیه تصویر دوربین} &= 15/9KB \\ k = \text{حجم فشرده شده با} \cdot 10 &= 13/3KB \end{aligned}$$


مشاهده می شود که حجم تصویر فشرده شده کمتر از حجم تصویر اصلی است. در اینجا برای به دست آوردن حجم تصویر اصلی و فشرده شده به صورت زیر عمل شده است: ابتدا بر روی تصویر مورد نظر کلیک راست کرده و گزینه Properties را انتخاب می کنیم سپس مطابق تصویر زیر می توانیم حجم تصویر را یادداشت نماییم. به نظر شما روش دیگری برای محاسبه حجم تصاویر اصلی و فشرده شده وجود دارد؟ پاسخ این سوال در تمرینات از شما خواسته شده است.





چند مثال و با مقادیر مختلف  $k$  در ادامه آورده شده است.


مثال ۷.۱۱



$$\text{حجم اولیه تصویر بیر} = ۵۳/۲KB \\ k = \text{حجم فشرده شده با} = ۴۲/۲KB$$

مشاهده می شود که تصویر برای  $k = 100$  از کیفیت خوبی برخوردار است و بعلاوه در این حالت حجم تصویر فشرده شده از حجم تصویر اصلی کمتر است.

## مثال ۷.۱۲




$$\text{حجم اولیه تصویر عکاس} = ۵/۲۶KB$$

$$k = ۱۰۰ \text{ حجم فشرده شده با } = ۶/۸۲KB$$

در تصویر بالا مشاهده می کنید که به ازای  $k = 100$  حجم تصویر فشرده شده در واقع از تصویر اصلی بیشتر است. پس مقدار  $k$  در این مثال به درستی انتخاب نشده است. اکنون ابتدا برنامه‌ی مربوط به فشرده سازی تصویر را اجرا و با اعمال آن بر عکس مربوط به تصویر عکاس حداکثر مقدار قابل برای  $k$  را به دست اورید. یعنی مقادیری از  $k$  را تعیین کنید که به ازای آنها حجم تصویر فشرده شده از حجم تصویر اصلی کمتر است. همانطور که می بینید با افزایش مقدار  $k$  کیفیت تصاویر افزایش می یابد. به نظر شما می توان مقدار بهینه ای برای  $k$  تعیین نمود؟

## مثال ۷.۱۳


در ادامه به فشرده سازی یک تصویر دیگر (تصویر کره ای ماه) می پردازیم. توجه کنید که برای  $k = 100$  تصویر از دقت بسیار خوبی برخوردار است.



$$\text{حجم اولیه تصویر ماه} = 6/30 KB$$
$$k = 100 \text{ حجم فشرده شده با} = 7/99 KB$$

## ۱.۸ فشرده سازی تصویر رنگی


در شکل زیر سه لایه رنگی که برای تصاویر رنگی استفاده می شود مشاهده می شود.



برای مثال تصویر رنگی زیر را در نظر بگیرید



در شکل زیر پیکسل‌های همین تصویر رنگی را با دستورات زیر به نمایش گذاشته‌ایم. همان‌طور که مشاهده می‌شود تصویر از ۳ لایه رنگی تشکیل شده است و درایه‌های هر لایه با هم متفاوت‌اند.



البته با دستور `rgb2gray(A)` می‌توان دید تصویر فراخوانده شده که ابتدا سه ماتریس کنار هم (ماتریس سه لایه) است را خاکستری نمود و درواقع آن را به ماتریس تبدیل نمود. توجه کنید که ممکن است در ظاهر تصاویری خاکستری باشند اما همچنان به صورت ماتریس سه لایه یکی هستند همان‌طور که در مثال قبل نیز دیدیم. در ادامه نحوه‌ی تبدیل تصویر رنگی به خاکستری با استفاده از نرم افزار متلب آمده است.

```


1 - A=imread('Nature.png');
2 - B=rgb2gray(A);
3 - subplot(1,2,1)
4 - imshow(A)
5 - subplot(1,2,2)
6 - imshow(B)

```


A 439x587x3 uint8  
B 439x587 uint8




همان‌طور که مشاهده می‌کنید تصویر رنگی به یک تصویر خاکستری تبدیل شده است و ماتریس حاصل آن که از بعد  $587 \times 439$  است در  $B$  ذخیره شده است. در شکل زیر همان‌طور که می‌بینید بعد از تبدیل شدن تصویر رنگی به تصویر خاکستری، این تصویر تنها از یک لایه تشکیل شده است.




با زوم بیشتر داریم




با زوم بیشتر داریم




با زوم بیشتر داریم



با زوم بیشتر داریم



با زوم بیشتر داریم




همانطور که می بینید با دستور  $\text{rgb2gray}(A)$  می توان دید تصویر فراخوانده شده که ابتدا یک ماتریس سه لایه است را خاکستری نمود و درواقع آن را به ماتریس تبدیل نمود. بخصوص در تصویر بالا می توانید ماتریس متناظر با تصویر خاکستری را مشاهده کنید.

اکنون به فشرده سازی تصویر رنگی می پردازیم. فشرده سازی تصاویر رنگی نیز همانند تصاویر خاکستری است. بویژه این کد نوشته شده در نرم افزار متلب مثال های قبل برای تصاویر رنگی نیز قابل استفاده است. در ادامه به فشرده سازی دو تصویر رنگی پرداخته ایم.

#### ۷.۱۴ مثال

ابتدا تصویر رنگی که در پایین دیده می شود را در کامپیوتر ذخیره کرده و سپس با استفاده از کد متلب بیان گردیده به فشرده سازی آن می پردازیم.



$$1/83MB = \text{حجم اولیه تصویر خودرو}$$

$$289KB = \text{حجم فشرده شده با } k=100$$


توجه کنید که برای  $k = 100$  تصویر از دقت خیلی خوبی برخوردار است. بعلاوه حجم تصویر فشرده شده به طور چشمگیری کاهش یافته است. به طور دقیق تر از آنجایی که

$$1/83MB = 1/83 \times 1024KB \approx 1874KB$$

$$\text{و } \frac{1}{6} \approx \frac{289}{1874} \text{ می توان گفت حجم تصویر فشرده شده به طور تقریبی } \frac{1}{6} \text{ حجم تصویر اصلی است.}$$

### مثال ۷.۱۵

در اینجا نیز تصویر رنگی که در پایین دیده می شود را ابتدا در کامپیوتر ذخیره کرده و سپس با استفاده از کد مطلب بیان گردیده به فشرده سازی آن می پردازیم.




$$k = 403KB$$
$$= 100\text{ جم فشرده شده با } 100\text{ جم اولیه تصویر برف}$$

در این مثال نیز برای چند تقریب رتبه پایین مختلف (یعنی چند  $k$  مختلف) تصویر فشرده شده را به دست آورده ایم. به وضوح با افزایش  $k$  کیفیت و دقت تصویر بیشتر می شود. البته بدیهی است که با افزایش  $k$  حجم تصویر فشرده شده نیز بیشتر می شود. به هر حال مشاهده می شود که تصویر حاصل به ازای  $k = 100$  هم از دقت خوبی برخوردار است و هم به حافظه ای کمتری برای ذخیره سازی نیاز دارد.

## 7.5 تمرین

تصویر رنگی که مربوط به آرامگاه حافظ شیرازی است را ابتدا در کامپیوتر ذخیره کرده و سپس با استفاده از کد مطلب بیان گردیده به فشرده سازی آن پرداخته ایم. با اجرای کد مطلب مربوط به این مثال در مورد  $k$  های مناسب برای ذخیره سازی این تصویر بحث کنید.





## واژه‌نامه انگلیسی به فارسی

### R

rank ..... رتبه  
rotation ..... دوران

### S

sampling ..... نمونه گیری  
Symmetric Matrix ..... ماتریس متران  
Signal Processing ..... پردازش سیگنال  
Similar Matrices ..... ماتریس‌های متشابه  
Singular Value Decomposition ..... تجزیه‌ی مقادیر تکین  
Solving Square Linear ..... حل دستگاه‌های خطی مربع  
Systems  
Solving the underdetermined ..... حل دستگاه فرومیعنی  
linear system  
Solving the overdetermined linear ..... حل دستگاه فرامیعنی  
system

### C

Coefficient Matrix ..... ماتریس ضرایب  
Compression ..... فشرده سازی

### D

Data Mining ..... داده کاوی  
Diagonalizable matrix ..... ماتریس قطری شدنی  
Digitization ..... دیجیتال کردن

### E

eigenvalue ..... مقدار ویژه  
eigenvector ..... بردار ویژه

### T

the last square solution ..... جواب کمترین مربعات  
The minimum norm solution ..... جواب کمترین نرم  
Transformation matrix ..... ماتریس تبدیل

### G

Gram-Schmidt Algorithm ..... الگوریتم گرام-اشمیت

### I

Image Processing ..... پردازش تصویر

### L

linear combination ..... ترکیب خطی

### O

Orthogonal Matrix ..... ماتریس متعامد

### P


pixel ..... پیکسل

### Q

Quantization ..... کمی‌سازی

## واژه‌نامه فارسی به انگلیسی

ر	rank ..... رتبه
ا	الگوریتم گرام-اشمیت ..... Gram-Schmidt Algorithm
ف	Compression ..... فشرده سازی
ب	eigenvector ..... بردار ویژه
ک	Quantization ..... کمی‌سازی
پ	Image Processing ..... پردازش تصویر
م	Signal Processing ..... پردازش سیگنال
	pixel ..... پیکسل
ت	Transformation matrix ..... ماتریس تبدیل
	Coefficient Matrix ..... ماتریس ضرایب
	Diagonalizable matrix ..... ماتریس قطربندی شدنی
	Orthogonal Matrix ..... ماتریس متعامد
	Symmetric Matrix ..... ماتریس مترقارن
	Similar Matrices ..... ماتریس‌های متشابه
	eigenvalue ..... مقدار ویژه
ج	sampling ..... نمونه‌گیری
	the last square solution ..... جواب کمترین مربعات
	The minimum norm solution ..... جواب کمترین نرم
ح	the overdetermined linear system ..... حل دستگاه فرامعین
	the underdetermined linear system ..... حل دستگاه فرومیعنی
	Solving Square Linear Systems ..... حل دستگاه‌های خطی مربع
د	Data Mining ..... داده کاوی
	rotation ..... دوران
	Digitization ..... دیجیتال کردن



دانشگاه صنعتی امیرکبیر  
(پلی تکنیک تهران)

---

## جبر خطی عددی

(کارشناسی)

فصل هفتم: تجزیه مقادیر تکین

مدرس: مهدی دهقان

---



دانشکده  
ریاضی و علوم کامپیوتر

---

۱۴۰۲-۱۴۰۳ ترم اول